

**PROFIELWERKSTUK INFORMATICA & BIOLOGIE**  
**BEGELEID DOOR JERINA VRIES & SONJA STEIGER**

# **HET TIJDPERK VAN** **SLIMME DIAGNOSES**

**PROFESSIONELE PERSPECTIEVEN EN PRAKTISCHE OPLOSSINGEN**

---

**Door Santos van der Wansem (V6D) en Mina Qayumzada (V6C)**

*16 februari 2024*



# Inhoudsopgave

<b>Voorwoord</b>	<b>4</b>
<b>Inleiding</b>	<b>5</b>
<b>Theoretisch kader</b>	<b>6</b>
1: De demystificatie van 'machine learning'	6
1.1: Wat is machine learning?	6
1.2: Welke soorten machine learning bestaan er?	6
Supervised learning	7
Unsupervised learning	7
Reinforcement learning	7
1.3: Hoe 'leren' die machines nou echt?	8
2: Het maken van een machine learning algoritme	9
2.1: Definieer het probleem	9
2.2: Het gebruiken van gegevens	9
2.3: Het kiezen van het juiste type model	10
Reinforcement learning	10
Unsupervised learning	11
Supervised learning	11
2.4: Het trainen van het algoritme	11
2.5: Het evalueren van het algoritme	12
Nauwkeurigheid	12
Verwarringsmatrix	12
Nauwkeurigheid per klasse	13
Logverlies	13
AUC (Area Under Curve)	13
3: Medische besluitvorming	14
3.1: Traditionele diagnostische methoden	14
Fysieke examens	14
Laboratoriumtests	14
Beeldvormingstechnieken	14
Biopsies	14
3.2: Uitdagingen en Beperkingen van Traditionele Methoden	15
Menselijke fouten	15
Tijdsintensieve processen	15
Beperkingen in vroegtijdige opsporing	15
4: Het verkrijgen en gebruiken van data	16
4.1: De noodzaak van data	16
4.2: Het verzamelen van data	16
Datamining	16
Databases	16
4.3: Medische databases	17
4.4: Het verwerken van data in python	18
Pandas	18
Matplotlib en Seaborn	18
Tensorflow	18

<b>Intermezzo</b>	<b>19</b>
<b>Deel 1: Algoritmische heelkunde: Het proces van creëren en verfijnen van machine learning modellen voor in de zorg</b>	<b>20</b>
Inleiding	20
Casus	20
Doelstelling	20
1.1: Vooronderzoek	21
Variabelen	21
Dataset	21
Technologieën	22
1.2: Datamanipulatie	22
1.3: Modelselectie	25
1.4: Model implementatie	29
<b>Deel 2: Verder dan de code: Begrijpen hoe machine learning de zorg kan transformeren</b>	<b>30</b>
1: De impact van een nieuwe diagnostische tool	31
1.1 Hoe kan het gebruik van machine learning in de diagnostiek de medische besluitvorming ondersteunen?	31
1.2 Wat is de potentiële impact van deze technologie op de patiëntenzorg en behandelingsuitkomsten?	32
2: De ethische implicaties van machine learning in de zorg	34
2.1: Wat zijn de ethische kwesties rond het gebruik van machine learning in de gezondheidszorg?	34
Privacy en gegevensbeveiliging	34
Algoritmische bias en discriminatie	34
Verantwoordelijkheid en aansprakelijkheid	34
Transparantie en uitlegbaarheid	35
Toestemming en autonomie van de patiënt	36
Onduidelijkheid bij de herkomst van de data	36
Wetgeving	36
2.2 Hoe kan de privacy van patiëntgegevens worden gewaarborgd bij het gebruik van machine learning-algoritmen in ziekenhuizen?	37
3: Het gebruiken van een nieuwe tool door doctoren	38
3.1 Wat zijn uitdagingen bij het implementeren van machine learning in ziekenhuizen?	38
3.2 Welke factoren kunnen van invloed zijn op de acceptatie door medisch personeel?	39
3.3 Wat voor soort training hebben medische professionals nodig om effectief gebruik te kunnen maken van machine learning-tools in de klinische praktijk?	40
<b>Literatuurlijst</b>	<b>41</b>
Literaire bronnen	41
Afbeeldingen	44
Tabellen	48
Grafieken	49
<b>Bijlage</b>	<b>51</b>
Procesverslag	52
Interviews met zorgprofessionals voor nieuwe inzichten	53
Gesprek met Johan Schuijtemaker	53
Gesprek met Marein van der Torn	55
<b>Logboek</b>	<b>56</b>

# Voorwoord

In dit profielwerkstuk verkennen we het fenomeen van machine learning in de zorg, een onderwerp waarbij de raakvlakken tussen biologie en informatica centraal staan. Dit project had niet tot stand kunnen komen zonder de deskundige begeleiding van onze docenten Jerina Vries en Sonja Stijger, aan wie wij zeer dankbaar zijn. Hun begeleiding was van onschatbare waarde en onmisbaar voor een complex onderwerp als deze. Dankzij hun gezamenlijke begeleiding hebben we niet alleen een dieper begrip ontwikkeld van machine learning in de zorg, maar hebben we ook waardevolle vaardigheden en kennis opgedaan die verder reiken dan dit project. Hun inzichten en feedback leidden ons ook tot de zoektocht naar meer diepgang in ons profielwerkstuk, waardoor we een gesprek konden houden met Johan Schuijtemaker (geriatriest) en vervolgens ook Marein van der Torn (KNO arts en CMIO van Dijklander ziekenhuis). Dus, zeker ook een speciale dank aan de deskundigen in het vakgebied van gezondheid die ons het missende puzzelstukje mee konden geven.

# Inleiding

In de moderne gezondheidszorg is de integratie van technologieën zoals machine learning niet langer een toekomstvisie, maar een realiteit die de potentie heeft om de medische praktijk ingrijpend te transformeren. Dit profielwerkstuk verkent de rol van machine learning in de zorg, met een bijzondere focus op de mogelijkheden voor het verbeteren van diagnostische precisie en het personaliseren van behandelingen. Door het analyseren van verschillende toepassingen en het beoordelen van de ethische en praktische uitdagingen, streeft dit werk naar een beter begrip van hoe kunstmatige intelligentie kan bijdragen aan de gezondheidszorg. Het uiteindelijke doel is het evalueren van de haalbaarheid en effectiviteit van machine learning algoritmen in het ondersteunen van medische professionals en het verbeteren van patiëntuitkomsten.

Bovendien gaat dit profielwerkstuk een stap verder door niet alleen de theoretische potentie van machine learning in de gezondheidszorg te onderzoeken, maar ook door het presenteren van een proof of concept. Dit toont de praktische haalbaarheid aan van het implementeren van machine learning technologieën in medische procedures en behandelingen. Door deze praktische benadering biedt het werkstuk inzicht in de realisatie van technologische innovaties binnen de medische sector en draagt het bij aan de discussie over de toekomstige richting van zorgtechnologieën.

Met deze fundamentele inzichten en een concrete demonstratie van de toepassing in de vorm van een proof of concept, legt dit profielwerkstuk de basis voor een diepgaande verkenning van de impact van machine learning op de gezondheidszorg. In de volgende hoofdstukken zullen we nader ingaan op specifieke case studies, de technische uitvoerbaarheid van machine learning modellen analyseren, en de ethische overwegingen bespreken die komen kijken bij het toepassen van deze technologieën in een medische context. Zo biedt dit werkstuk niet alleen een theoretisch kader, maar ook een praktisch perspectief op de revolutionaire mogelijkheden die machine learning biedt voor de toekomst van de gezondheidszorg.

# Theoretisch kader

In dit profielwerkstuk wordt onderzoek gedaan naar hoe ziekenhuizen geholpen kunnen worden door met behulp van machine learning een tool te ontwikkelen waarbij doktoren ondersteund worden bij het leveren van prognoses en diagnoses. Om uiteindelijk zo'n tool te ontwikkelen, is veel onderzoek nodig. Thema's zoals de huidige manier waarop doktoren diagnoses en prognoses leveren, manieren waarop machine learning momenteel al in de zorg wordt gebruikt, wat de (ethische) implicaties zijn van het gebruiken van dergelijke tools en wat het eventuele effect hiervan zou kunnen zijn, zijn allemaal belangrijke thema's die de bouwstenen zullen vormen voor dit gehele onderzoek.

Dit onderzoek zal uit twee delen bestaan die uiteindelijk in harmonie zullen samenkomen: een medisch en een technisch gedeelte. Het doel van dit profielwerkstuk is om uiteindelijk een proof-of-concept algoritme te creëren, waarmee we willen bewijzen dat het mogelijk is om een hulpmiddel te creëren waarbij ziekenhuizen ondersteund worden in het proces van het diagnosticeren en het leveren van een prognose aan hun patiënten. In het theoretisch kader zullen er dus met behulp van een bronnenonderzoek, verschillende vragen beantwoord worden die uiteindelijk bij zullen dragen aan de ontwikkeling van het algoritme.

## 1: De demystificatie van 'machine learning'

### *1.1: Wat is machine learning?*

Machine learning is, om het simpel te zeggen, een domein binnen de kunstmatige intelligentie waarbij computers aan de hand van data leren om algoritmes te ontwikkelen en deze verbeteren. De computers hoeven niet steeds zelf bijgesteld te worden en proberen aan de hand van data hun algoritmes zo accuraat mogelijk te maken. Het voordeel daarvan is dat er relatief weinig ingrijpen van mensen nodig is om een efficiënt algoritme te maken. Er zijn verschillende manieren waarop machine learning kan worden toegepast, zoals bijvoorbeeld bij het herkennen van foto's of bij het voorspellen van informatie.

### *1.2: Welke soorten machine learning bestaan er?*

Machine learning kan op verschillende manieren gedaan worden, om verschillende doelen te bereiken. Er zijn drie paradigma's die vaak toegepast worden: supervised, unsupervised en reinforcement learning.

### Supervised learning

Bij deze soort van machine learning wordt er op basis van een input en een gewenste output waarde een model getraind waarbij wordt gekeken naar hoe groot de kans is dat een bepaalde input resulteert in een bepaalde output. Het heet supervised omdat het model gelabelde input krijgt en deze omzet in een voorspelling. Het model wordt dus begeleid door de labels van de data. Er is veel data nodig om een supervised machine learning model te creëren, omdat het model veel fouten zal moeten maken om uiteindelijk accurate voorspellingen te kunnen maken. (Mohri et. al., 2012)

### Unsupervised learning


Bij deze vorm van machine learning worden algoritmes getraind met ongelabelde data. Om met deze data voorspellingen te kunnen doen kan een algoritme de data bijvoorbeeld indelen in clusters op basis van overeenkomsten. Een voordeel hiervan is dat de computer overeenkomsten kan vinden die voor mensen misschien onbekend zijn. Een algoritme dat vaak gebruikt wordt bij unsupervised learning is *K-means clustering*, waarbij via een wiskundige berekening data wordt ingedeeld op basis van hun 'afstand' tot een cluster. (Mohri et. al, 2012)

### Reinforcement learning

Bij dit machine learning paradigma worden agents (entiteiten die in de simulatie de gebruiker vertegenwoordigen) ingezet om in een dynamische omgeving acties uit te voeren om een bepaald doel te bereiken. Elke keer dat dit doel bereikt wordt, wordt de agent beloond, waardoor deze onthoudt om soortgelijke stappen de volgende keer weer te nemen. Daarnaast worden foute resultaten gestraft. Dit soort machine learning is gebaseerd op het proces van trial and error. De agent streeft naar een maximalisatie van beloningen en zal daarom altijd proberen om efficiënter te worden. Manieren waarop dit gebruikt wordt is bijvoorbeeld om robots te laten leren bewegen of door non-playable characters in videogames te trainen om het tegen iemand op te nemen in een spel. (Hashemi-Pour & Carew, 2023)

### 1.3: Hoe 'leren' die machines nou echt?

De term 'machine learning' doet denken dat machines echt aan het leren zijn, en hoewel dit in zekere zin klopt, is het niet helemaal accuraat. Machine learning is namelijk geen magisch proces, maar probeert de manier waarop de mens nadenkt na te bootsen met 'neurale netwerken', zoals die van de hersenen. Deze neurale netwerken zijn opgebouwd uit neuronen, ook wel nodes genoemd die met elkaar communiceren. Zo'n netwerk, een Artificial Neural Network (ANN) heeft meerdere lagen waarin de nodes zich bevinden: een input laag, waar de gegevens ontvangen worden, een of meer verborgen lagen, waar de data verwerkt wordt, en een output laag waarin feedback wordt verzonden. Een voorbeeld van zulke feedback kan bijvoorbeeld zijn dat het netwerk de letter 'a' heeft herkend in een foto. Zoals op de foto hiernaast te zien is zijn de nodes van de lagen allemaal met elkaar verbonden, deze verbindingen hebben een bepaalde waarde, een gewicht, die aangeeft hoe belangrijk die connectie is en hoeveel die connectie zal meewegen bij het bepalen van de output. De data van de ene node wordt doorgespeeld naar alle volgende nodes en dat betekent dat het een 'feedforward' netwerk is. (IBM, z.d.)



Afbeelding 1: Een weergave van een Artificial Neural Network (IBM, z.d.)



## 2: Het maken van een machine learning algoritme

### 2.1: Definieer het probleem

Machine learning algoritmes zijn handig omdat ze voorspellingen kunnen doen zonder het ingrijpen van mensen, wat veel tijd kan besparen. Om te beginnen aan het creëren van een dergelijk algoritme is het belangrijk om te weten wat het probleem precies is en wat er opgelost moet. Het is dus belangrijk om de vraag te stellen wat er precies voorspeld wordt en welke gegevens invloed op de voorspelling zullen hebben. Bij het voorspellen van een bepaalde hartkwaal zal het cholesterolgehalte bijvoorbeeld een belangrijke rol spelen en moet deze dus betrokken worden in het model. Als we voorspellingen willen gaan maken over een bepaalde situatie moeten we dus rekening gaan houden met welke inputvariabelen er verwerkt moeten worden en welke output variabele er moet komen. (Roman, 2021)

Van tevoren moet er vastgesteld worden hoe een succesvol resultaat eruit moet zien. Dat zou bijvoorbeeld zijn dat het model met bepaalde waarden van variabelen X en Y een bepaalde uitkomst moet leveren bij output variabele Z. Hoe succesvol een model is hangt dan af van hoe vaak het model de gewenste waarde Z geeft bij bepaalde waarden van X en Y.

### 2.2: Het gebruiken van gegevens

Zodra het probleem, de gewenste uitkomst en de benodigde variabelen bekend zijn, is het tijd om te zoeken naar bruikbare datasets die alle benodigde gegevens bevatten. Hoe deze data verzameld en verwerkt kunnen worden, wordt uitgebreid besproken in hoofdstuk 4 van het theoretisch kader, omdat het een erg complexe zaak is.

Wanneer er bekend is welke gegevens nodig zijn voor het algoritme, moet er gekeken worden naar in welke vorm zulke gegevens voorkomen. Zo kunnen patiëntengegevens bijvoorbeeld bloedwaardes zijn, die als nummers of tekst weergegeven kunnen worden, of MRI scans die als foto's weergegeven worden. Het is dus belangrijk om de kenmerken van de variabelen te identificeren.

De doelvariabele kan ook verschillende vormen aannemen, zo kan het bijvoorbeeld een zin voorspellen, een getal, of misschien gewoon een 1 of een 0 om te laten weten of iets wel of niet waar is. Een voorbeeld van een doelvariabele is bijvoorbeeld een getal tussen de 0 en 100 bij een model dat klanttevredenheid voorspelt om aan te duiden hoe tevreden een klant zou kunnen zijn. Daarnaast zijn er ook modellen waarbij er op basis foto's van met de hand geschreven letters er als output een letter wordt gegenereerd waarvan het model denkt dat het overeenkomt met de foto.

Zodra de eigenschappen van de variabelen bekend zijn is het tijd om te dataset 'op te schonen' als het ware, waarbij verschillende onnodige variabelen of onvolledige informatie uit de dataset verwijderd wordt, zodat deze makkelijker wordt om mee te werken. Daarna is het tijd om data te normaliseren, wat betekent dat de waarden van de variabelen worden aangepast zodat ze allemaal op dezelfde schaal komen en dus makkelijker met elkaar vergeleken kunnen worden. Ten slotte zal de data ook opgesplitst moeten worden in 3 delen: een trainingsset, waarmee het model getraind wordt, een testset, waarmee gekeken wordt of het model correct functioneert en een validatieset waarbij de puntjes op de i worden gezet door parameters op hyperparameters af te stemmen. Daarnaast zijn er nog technieken zoals cross-validation waardoor datasets hergebruikt kunnen worden. Hoe deze processen eruit zien in de praktijk zal in een later hoofdstuk besproken worden. (Birba, 2020)

### *2.3: Het kiezen van het juiste type model*

Zoals al in het eerste hoofdstuk is besproken zijn er verschillende machine learning modellen, waaronder supervised, unsupervised en reinforcement modellen. Welke van deze modellen het beste van toepassing zijn hangt af van een aantal eigenschappen van het probleem, de dataset en het resultaat dat bereikt moet worden.

#### **Reinforcement learning**

Dit type model van machine learning wordt vooral vaak toegepast in situaties waarin agents met hun omgeving moeten omgaan. De vraag is of er bepaalde acties zijn die agents in een omgeving kunnen doen waar ze uiteindelijk van kunnen leren. Dit wordt vaak gebruikt voor het maken van onder andere games en simulaties. Deze vorm van machine learning is niet bruikbaar bij het creëren van een algoritme dat diagnoses levert en zal dus niet verder besproken worden in dit verslag, maar het is wel belangrijk om te weten wat er relevant en van belang is indien dit model gebruikt wordt. Zo moet er nagedacht worden over of er een dynamische omgeving is waarmee een agent moet omgaan, of de resultaten van de agent vertaald kunnen worden naar beloningen en straffen of dat de volgende actie afhangt van eerdere acties? Indien het antwoord op een van deze vragen ja is, zou reinforcement learning goed toegepast kunnen worden. (Hashemi-Pour & Carew, 2023)

### Unsupervised learning

Bij unsupervised machine learning worden ongecategoriseerde gegevens gebruikt om patronen te ontdekken. Ongecategoriseerde gegevens zijn bijvoorbeeld waarden zonder titel, waardoor niet zeker is wat ze precies zijn. Met behulp van bepaalde algoritmes, zoals K-means clustering, kunnen deze waarden toch erg bruikbaar worden. Met deze vorm van machine learning kunnen onderliggende structuren openbaren. Een dergelijk model zal dus van toepassing zijn als de data die gebruikt moet worden geen labels heeft of als er complexe interacties tussen kenmerken zijn die begrepen moeten worden. Al met al is dit model dus ook niet toepasselijk voor diagnosticering, maar wel voor veel andere probleemstellingen. (Mohri et. al., 2012)

### Supervised learning

Bij dit soort machine learning worden op basis van de waarden van bepaalde variabelen voorspellingen gedaan. Een paar vragen die gesteld moeten worden zijn bijvoorbeeld of de beschikbare data gelabeld zijn en of er een bepaalde waarde voorspeld moet worden. Bij een taak zoals diagnosticering is deze vorm van machine learning het meest geschikt aangezien de data die ziekenhuizen opslaan gelabeld moeten zijn en er op basis van die gegevens een voorspelling moet worden gemaakt. Supervised learning is namelijk het beste model voor binary classification, waarbij in dit geval op basis van hun gegevens een patiënt een van twee labels kan ontvangen: “lijdt aan ziekte X” of “lijdt niet aan ziekte X”. Omdat er maar twee mogelijke opties zijn die het model zal kunnen toewijzen, heet het een binary classification model. Deze manier van machine learning wordt onder andere gebruikt bij het leveren van productaanbevelingen aan gebruikers, gezichtsherkenning, spamfiltering bij mails en op nog veel meer manieren. Een andere wijze waarop computers voorspellingen kunnen doen heet regressie (van het Engelse ‘regression’), waarbij er niet zomaar een klasse wordt toegewezen, maar er een continue waarde wordt voorspeld, zoals bijvoorbeeld een leeftijd. (Mohri et. al, 2012)

## 2.4: Het trainen van het algoritme

Het trainen van het algoritme is een erg complexe zaak die met elke dataset en doel verschilt en zal dus ook niet stapsgewijs kunnen worden uitgelegd in het theoretisch kader. Enige zaken die bij het trainen van elk algoritme van toepassing zijn, zoals het opschonen van de data bijvoorbeeld, zullen besproken worden in hoofdstuk 4 van het theoretisch kader. Het coderen van het algoritme kan op verschillende manieren en met verschillende programmeertalen gedaan worden, waaronder bijvoorbeeld python, javascript, maar ook vele andere talen. Python wordt vaak aangeraden als beste programmeertaal door haar vele functies en makkelijke syntaxis en zal dus ook de taal zijn die wij gaan gebruiken bij het ontwikkelen van het model.

## 2.5: Het evalueren van het algoritme

Het evalueren van een algoritme is een erg belangrijk onderdeel van het ontwikkelproces omdat er hier als het ware feedback wordt gegeven op de prestaties van het algoritme en hoe deze weer kunnen toepassen op het model. Er zijn verschillende manieren waarop een machine learning algoritme beoordeeld kan worden, maar de meest voorkomende zijn de AUC (area under curve), de RMSE (root mean square error) en de normalized discounted cumulative gain (NDCG). Voor dit onderzoek zijn echter alleen de manieren om binary-classification modellen te beoordelen belangrijk. Degene die het vaakst gebruik worden bij deze modellen zijn: het meten van accuraatheid, de verwarrings-matrix, logverlies en de AUC (area under curve).

### Nauwkeurigheid

Bij de nauwkeurigheid wordt er simpelweg gekeken naar de verhouding tussen juiste en onjuiste classificeringen. De formule hiervoor is:  $\frac{\# \text{correcte voorspellingen}}{\# \text{totale voorspellingen}}$ . Het nadeel hieraan is dat er geen onderscheid wordt gemaakt tussen hoe vaak de verschillende klassen juist of onjuist worden geclassificeerd. (Zheng, 2015)

### Verwarringsmatrix

Indien er ook rekening gehouden moet worden met hoe vaak de bepaalde klassen juist en onjuist geclassificeerd worden is dit een goede optie. Dit onderscheid kan bijvoorbeeld gemaakt worden omdat een van de twee klassen veel meer beschikbare trainingsdata heeft en het model hierdoor een bias krijgt voor deze klasse. Een dergelijke matrix ziet er als volgt uit:

	Positief voorspeld	Negatief voorspeld
Gelabeld als positief	80	20
Gelabeld als negatief	5	195

Tabel 1: Een weergave van een verwarringsmatrix

Het is uit de matrix af te leiden dat de positieve klasse een lagere nauwkeurigheid heeft dan de negatieve klasse:  $80 / 100 = 80,0\%$  (positief) is namelijk lager dan  $195 / 200 = 97,5\%$  (negatief) en is dus minder nauwkeurig. Indien we alleen naar de nauwkeurigheid  $((80 + 195) / (100 + 200) = 91,7\%$  zouden kijken, zouden we hier niet achter komen. (Zheng, 2015)

### Nauwkeurigheid per klasse

Dit is een variatie van de standaard manier om nauwkeurigheid te berekenen waarbij de het gemiddelde van de nauwkeurigheden van de verschillende klassen wordt genomen, oftewel:

$\frac{\text{nauwkeurigheidA} + \text{nauwkeurigheidB}}{\# \text{ klassen}}$  wat er in dit geval zo uit zou zien:  $\frac{80,0 + 97,5}{2} = 88,75\%$ , wat een iets betere weergave geeft van de nauwkeurigheid van het model, maar uiteraard nog niet helemaal perfect is. (Zheng, 2015)


### Logverlies

Deze manier kan worden toegepast in gevallen waarbij de output van het model een numerieke kans is in plaats van een binaire klasse (0 of 1). Het kan bijvoorbeeld weleens voorkomen dat de kans dat een patiënt een bepaalde kwaal heeft 51% is. Het model zou dan bij binaire classificatie het label positief toedienen, terwijl dit niet per se het geval hoeft te zijn. Bij logverlies wordt er met zulke gevallen rekening gehouden. De formule ziet er als

volgt uit:  $\text{logverlies} = -\frac{1}{N} \sum_{i=1}^N y_i \log p_i + (1 - y_i) \log (1 - p_i)$ . Deze formule stelt dat bij  $p_i$  de kans is dat het datapunt  $i$  tot klasse 1 behoort en dat  $y_i$  de daadwerkelijke klasse van datapunt  $i$  is. (Zheng, 2015)

### AUC (Area Under Curve)

In dit geval wordt er gekeken naar het gebied onder de ROC (Receiver Operating Characteristic) curve. Deze curve laat de gevoeligheid van het model zien door de valse positieve en negatieve classificaties te vergelijken met de juiste classificaties. AUC is een manier om de ROC curve in een getal samen te vatten. Des te hoger het AUC is, des te nauwkeuriger het model en is het dus beter. Bij een lagere AUC betekent het dat het model vaak verkeerd voorspelt wat niet wenselijk is. Een goede ROC curve heeft een groot gebied eronder, met een AUC van 100% als maximaal percentage (wat in de praktijk bijna nooit bereikt wordt). (Zheng, 2015)



Afbeelding 2: Een weergave van positieve en negatieve classificaties die met de ROC curve weergegeven worden. (Wikipedia, 2023)

## 3: Medische besluitvorming

### 3.1: Traditionele diagnostische methoden

In de hedendaagse medische wereld is diagnostiek een cruciaal aspect, dat voortdurend evolueert met de vooruitgang in technologie en medisch onderzoek. Het vermogen om ziekten nauwkeurig en snel te diagnosticeren is van fundamenteel belang voor effectieve gezondheidszorg. Moderne diagnostische methoden combineren traditionele klinische beoordelingen met geavanceerde technologieën, waardoor artsen een dieper en duidelijker inzicht krijgen in de gezondheidstoestand van patiënten.

#### Fysieke examens

Fysieke examens zijn de eerste stap in het diagnostisch proces. Artsen gebruiken hun zintuigen (zicht, gehoor, reuk en tast), kennis en eenvoudige instrumenten (zoals bijvoorbeeld een stethoscoop of reflexhamer) om tekenen van ziekte te identificeren. Deze examens kunnen algemene gezondheidsindicatoren zoals hartslag, bloeddruk, lichaamstemperatuur en ademhalingsfrequentie beoordelen.

#### Laboratoriumtests

Laboratoriumtests omvatten een breed scala aan tests, zoals bloedonderzoek, urineanalyse en microbiologische culturen. Deze tests kunnen helpen bij het identificeren van infecties, bloedstoornissen, hormonale onbalans en meer. Ze zijn cruciaal voor het bevestigen van diagnoses die worden vermoed op basis van fysieke examens en patiëntgeschiedenis.

#### Beeldvormingstechnieken

Beeldvormingstechnieken zoals MRI (Magnetic Resonance Imaging), CT-scans (Computed Tomography) en röntgenfoto's bieden gedetailleerde beelden van interne structuren van het lichaam. MRI is bijzonder nuttig voor het in beeld brengen van zachte weefsels, terwijl CT-scans uitstekend zijn voor het bekijken van botten en organen. Deze technieken zijn essentieel voor het diagnosticeren van aandoeningen zoals breuken, tumoren en interne bloedingen.

#### Biopsies

Een biopsie is een procedure waarbij een klein weefselmonster wordt genomen voor microscopisch onderzoek. Dit is vooral belangrijk in de oncologie voor het diagnosticeren van kanker. Biopsies kunnen bevestigen of een tumor goedaardig of kwaadaardig is en helpen bij het bepalen van de meest geschikte behandeling.

### 3.2: *Uitdagingen en Beperkingen van Traditionele Methoden*

Hoewel traditionele diagnostische methoden een essentiële rol spelen in de medische praktijk, brengen ze aanzienlijke uitdagingen en beperkingen met zich mee. Deze beperkingen benadrukken de noodzaak van voortdurende innovatie en verbetering in diagnostische methodologieën.

#### Menselijke fouten

Een aanzienlijke beperking van traditionele diagnostische methoden is de mogelijkheid van menselijke fouten. Fouten kunnen optreden in elke fase van het diagnostisch proces, van het nemen van monsters tot het interpreteren van resultaten. Deze fouten kunnen leiden tot verkeerde diagnoses en ongeschikte behandelingen. (Christel van Moll et al., 2023)

#### Tijdsintensieve processen

Veel traditionele diagnostische methoden zijn tijdsintensief. Het kan dagen of zelfs weken duren voordat de resultaten van sommige tests beschikbaar zijn, wat de behandeling kan vertragen. In acute of levensbedreigende situaties kan deze vertraging fataal zijn. (Moll et al., 2023)

#### Beperkingen in vroegtijdige opsporing

Sommige ziekten, vooral in hun vroege stadia, zijn moeilijk te detecteren met traditionele methoden. Bijvoorbeeld, veel soorten kanker vertonen in de vroege stadia weinig tot geen symptomen en zijn mogelijk niet zichtbaar met standaard beeldvormingstechnieken. Dit kan leiden tot late diagnoses, wanneer de ziekte al in een gevorderd stadium is. En late diagnoses kunnen ook diagnostische fouten bevatten, wat zeer ernstige gevolgen kan hebben. Jaarlijks worden bijvoorbeeld ongeveer 800.000 Amerikanen verkeerd gediagnosticeerd en ondervinden hier fatale gevolgen van (Johns Hopkins Medicine, 2023).

## 4: Het verkrijgen en gebruiken van data

### 4.1: De noodzaak van data

Een machine learning algoritme heeft gegevens nodig om getraind te kunnen worden. Dit is omdat deze algoritmes zichzelf telkens corrigeren, op basis van de input (data) die ze ontvangen. Een machine learning algoritme met een beperkt aantal data zal moeite hebben om zich te kalibreren en zal uiteindelijk dus minder accuraat worden. Data kan verschillende vormen aannemen en het is dus belangrijk om van tevoren na te denken over welke soort informatie er geanalyseerd moet worden in het model. Voorbeelden van de soorten data zijn bijvoorbeeld audiobestanden, foto's, teksten, etc. die gebruikt kunnen worden om de modellen te trainen.

### 4.2: Het verzamelen van data

De manieren waarop data verzameld kunnen worden verschillen, de manier waarop een grote organisatie deze kan verzamelen verschilt namelijk van de manier waarop een individuele onderzoeker deze verzamelt. Er zit daarnaast ook een verschil tussen het verzamelen van data die zelf geproduceerd is (zoals bijvoorbeeld een steekproef) of data verzamelen van andere instanties.

#### Datamining

Datamining, oftewel 'data delven' is het verzamelen van gegevens door deze te zoeken in een grote hoeveelheid data. Het kan vergeleken worden met zoeken naar een speld in een hooistapel. Bij datamining wordt er door gericht te zoeken naar specifieke gegevens die bijvoorbeeld van databases of van het internet kunnen komen. Een techniek binnen het datamining is web scraping, waarbij websites worden bezocht en belangrijke data wordt geëxtraheerd. Data mining is een complexe strategie om data te verzamelen omdat er allerlei wiskundige analytische functies bij komen kijken die helpen bij het herkennen van bepaalde trends, patronen of informatie. Data mining kan gedaan worden op grote schaal, maar is ook een toegankelijke techniek voor amateurs. Data mining wordt door verschillende sectoren gedaan omdat het bij veel taken kan helpen, zoals bijvoorbeeld bij data-analyse bij de marketingafdeling van een bedrijf of bij het trainen van kunstmatige intelligentie modellen. (Stedman & Hughes, 2021)

#### Databases

Een vaak gebruikte en welbekende manier om data te verzamelen is het opslaan van data in databases. Een database is een gestructureerde omgeving waarin data wordt opgeslagen. Het voordeel van een database is dat de gegevens die erin opgeslagen zijn makkelijk op te halen zijn, waardoor deze goed gebruikt kunnen worden in verschillende contexten.



De data in een database moet volgens een bepaalde manier ingedeeld worden waardoor het een goede manier is om data die later gebruikt kan worden voor een machine learning algoritme op te slaan. Databases worden overal gebruikt, in restaurants om de betalingen te overzien, op websites om gegevens te weergeven, en in ziekenhuizen om de gegevens van patiënten op te slaan. Gegevens van patiënten die worden opgeslagen bevatten zo'n beetje alles: informatie over hun identiteit, moment van opname, eventuele procedures die de patiënten zijn ondergaan, medicijnen die de patiënten zijn toegediend, diagnoses die aan patiënten zijn toegediend, MRI scans, etc. Zulke gegevens zijn erg bruikbaar om een machine learning algoritme te trainen om diagnoses en prognoses te stellen. (Date, 2003)

### *4.3: Medische databases*

Ziekenhuisbezoeken: naar de gynaecoloog, een operatie, of om wat voor reden dan ook, alle gegevens worden opgeslagen. Een aantal bestanden per persoon, waar de identiteit, leeftijd, medische gegevens, etc. in opgeslagen staan, worden samen verzameld in een database. Zo'n dergelijke database wordt vandaag de dag in de moderne wereld door zowat elk ziekenhuis ter wereld bijgehouden. De gegevens in zulke databases kunnen gebruikt worden om data te analyseren en om machine learning algoritmes te trainen. Het probleem met het gebruiken van zulke informatie is dat het in een ethisch grijs gebied ligt aangezien het privacyschending kan zijn om de privégegevens van mensen te gebruiken in zulke modellen. De oplossing hierop zullen we in een later hoofdstuk bespreken. Een openbare database die de privacy van patiënten beschermt en dus vaak door onderzoekers wordt gebruikt is de MIMIC-III database, waarin verschillende gegevens te vinden zijn: resultaten van bloedonderzoeken, door een patiënt ondergane behandelingen, opname en ontslaggegevens, toegediende medicijnen, diagnoses en andere gegevens (die in de bijlage gevonden kunnen worden). (Johnson et. al, 2016)

#### *4.4: Het verwerken van data in python*

Data is het belangrijkste onderdeel van een machine learning algoritme, dus het is belangrijk om te weten hoe deze bewerkt kunnen worden om een dataset te transformeren zodat deze bruikbaar is voor een machine learning algoritme. Het trainen van het algoritme wordt in verschillende stappen gedaan. Bij al deze stappen passen verschillende libraries (softwarepakketten) die al code hebben geschreven waarmee veel taken makkelijker kunnen worden uitgevoerd.

##### **Pandas**

Pandas is een python library dat gericht is op data-analyse. Pandas staat bekend om het DataFrame object, dat het mogelijk maakt om data te manipuleren. Pandas werkt met verschillende dataformaten, zoals CSV bestanden, tekstbestanden, SQL databases en nog meer vormen. Daarnaast maakt pandas het mogelijk om datasets op te splitsen in verschillende subsets, wat ook van pas kan komen bij het creëren van een machine learning algoritme. Pandas geeft dus mogelijkheden om datasets op te schonen en ze te manipuleren.

##### **Matplotlib en Seaborn**

Matplotlib is een library dat helpt bij het visualiseren van data. Bij het creëren van een algoritme is het handig om de data te kunnen weergeven zodat onderzoekers alvast kunnen speculeren over eventuele verbanden. Bij regressiemodellen zullen de errorplots bijvoorbeeld erg van pas kunnen komen tijdens het ontwikkelen van het model. Seaborn is een library dat gebouwd is op matplotlib en dus dezelfde functies bevat, maar is geavanceerder omdat deze ook geïntegreerd is met de dataframe objecten van pandas.

##### **Tensorflow**

Tensorflow is een library gemaakt om te helpen bij het creëren van machine learning algoritmes. Zulke algoritmes bestaan uit “tensors”, multidimensionale arrays die de gegevens representeren die uiteindelijk verwerkt worden in het algoritme. Tensorflow heeft allerlei functies die ontwikkelaars ondersteunen bij het ontwikkelen van neurale netwerken. Met tensorflow worden niet alleen modellen gebouwd, maar ook debugged en geanalyseerd, wat helpt om de nauwkeurigheid en dus de kwaliteit van het model te verbeteren.

## Intermezzo

Nu het theoretische gedeelte van het profielwerkstuk is behandeld, wordt er overgestapt naar het praktische en het onderzoekende gedeelte van het profielwerkstuk. In deel 1, het praktische gedeelte, wordt er verdiept in het ontwikkelen en beoordelen van een machine learning model, zoals beschreven in het theoretisch kader. In deel 2, het onderzoekende gedeelte, zullen de onderzoeksvragen worden beantwoord.

De hoofdvraag van dit onderzoek is: **Hoe kunnen ziekenhuizen geholpen worden door, met behulp van machine learning, algoritmes te ontwikkelen die patiënten diagnosticeren en een prognose leveren?**

Daarnaast zijn er een aantal deelvragen die per categorie worden ingedeeld, om op die manier de verschillende aspecten van machine learning in de zorg in kaart kunnen brengen.

Hoofdstuk 1: De impact van een nieuwe diagnostische tool

- Hoe kan het gebruik van machine learning in de diagnostiek de medische besluitvorming ondersteunen?
- Wat is de potentiële impact van deze technologie op de patiëntenzorg en behandeling uitkomsten?

Hoofdstuk 2: De ethische implicaties van machine learning in de zorg

- Wat zijn de ethische kwesties rond het gebruik van machine learning in de gezondheidszorg?
- Hoe kan de privacy van patiëntgegevens worden gewaarborgd bij het gebruik van machine learning-algoritmen in ziekenhuizen?

Hoofdstuk 3: Het gebruiken van een nieuwe tool door doctors

- Wat zijn uitdagingen bij het implementeren van machine learning in ziekenhuizen?
- Welke factoren kunnen van invloed zijn op de acceptatie door medisch personeel?
- Wat voor soort training hebben medische professionals nodig om effectief gebruik te kunnen maken van machine learning-tools in de klinische praktijk?

# Deel 1: Algoritmische heelkunde: Het proces van creëren en verfijnen van machine learning modellen voor in de zorg

De sourcecode, de data die gebruikt is voor het trainen voor het model en het model zelf zijn te vinden op github: <https://github.com/santosvdw/pws>.

## *Inleiding*

Kunstmatige intelligentie gebruiken in de zorg klinkt als iets dat zou plaatsvinden in het jaar 2100, maar is vandaag de dag al de realiteit in vele aspecten in de zorg. Zo worden er bijvoorbeeld chatbots ontwikkeld, die mensen vragen kunnen stellen over dingen die ze willen weten. Daarnaast wordt er ook in verschillende ziekenhuizen geëxperimenteerd met het uitbreiden van de rol van kunstmatige intelligentie in hun ziekenhuizen. In dit deel van het onderzoek zal er stap voor stap besproken worden hoe een machine learning algoritme daadwerkelijk ontwikkeld en verfijnd kan worden.

## *Casus*

Acuut nierfalen is een complexe aandoening die vaak voorkomt bij volwassenen op de intensive care-afdeling. Acuut nierfalen wordt gekenmerkt door een abrupte (binnen enkele uren) afname van de nierfunctie, wat zowel structurele schade aan de nieren als functieverlies inhoudt. Dit leidt tot een ophoping van afvalproducten in het bloed en verhindert de nieren om de juiste vochtbalans in het lichaam te handhaven. Acuut nierfalen is een ernstig syndroom vanwege de gerelateerde morbiditeit en mortaliteit. Er zijn echter een paar markers voor acuut nierfalen, deze markers zullen voor dit machine learning model de basis vormen voor de manier waarop het model de voorspellingen zal doen.

## *Doelstelling*

Het doel van dit machine learning model is niet om een 100% AUC te bereiken (oftewel om volledig accurate voorspellingen te doen), maar zal dienen als een proof of concept waar onderzoekers op voort kunnen bouwen. Dit model zal, met behulp van data uit een medische dataset, voorspellingen doen over of een patiënt lijdt aan acuut nierfalen. In andere woorden: dit model zal een voorspelling doen aan de hand van bestaande patiëntengegevens om diagnoses te leveren over of een patiënt lijdt aan acuut nierfalen.

## 1.1: Vooronderzoek

### Variabelen

Helaas zijn de voornaamste biomarkers van acuut nierfalen, zoals serum creatinine (SCr), late indicatoren van nierschade en kunnen ze uren tot dagen na de initiële nierinsult achterblijven, wat diagnose en behandeling vertraagt. Vroege herkenning van acuut nierfalen is van groot belang.

Biomarkers die mogelijk gebruikt kunnen worden om acuut nierfalen te voorspellen, omvatten onder andere serum creatinine (SCr) maar ook urine-output (UO). SCr is dus echter bekend als een ongevoelige marker die achterloopt op nierschade. Het onderzoek naar nieuwe biomarkers en methoden, waaronder machine learning toegepast op uitgebreide gezondheidsdossiers, is veelbelovend om deze problemen aan te pakken en modellen te ontwikkelen voor de vroege voorspelling van acuut nierfalen op de intensive care-afdeling.

Wel is het belangrijk te beseffen dat de interpretatie van deze biomarkers een lastige taak is, waarbij de context van de patiënt en de specifieke klinische situatie altijd in overweging moeten worden genomen. Zaken zoals leeftijd, etniciteit en geslacht kunnen ook meetellen als variabele en dus ook van belang zijn. In de klinische praktijk is een uitgebreide beoordeling essentieel om deze biomarkers effectief te gebruiken, een taak die zowel uitdagend als veelbelovend is in de voortdurende strijd tegen nierziekten.

### Dataset

Het Beth Israel Deaconess Medical Center in Boston, VS heeft hun elektronische patiëntgegevens van 2001 tot 2012 gepubliceerd, met als doel onderzoekers een uitgebreide dataset te bieden voor onderzoeksdoeleinden. De dataset, genaamd MIMIC-III, bestaat uit 26 losse .csv bestanden en is gevuld met de geanonimiseerde patiëntgegevens van 40.000 Amerikanen. Een beschrijving van de 26 tabellen is te vinden in de bijlage. (Johnson et. al, 2016)

## Technologieën

De programmeertaal python staat bekend om het feit dat het uitgebreide mogelijkheden biedt voor machine learning. Bij de ontwikkeling van het model zal gebruik gemaakt worden van Google Colab, een online platform dat de mogelijkheid biedt om een python notebook gratis in de cloud uit te voeren. Er zal bij de ontwikkeling van het model gebruik gemaakt worden van verschillende python libraries, welke libraries dat zijn en hoe ze gebruikt worden zal later besproken worden.

### 1.2: Datamanipulatie

Bij deze stap wordt de dataset, bestaand uit 26 tabellen, omgezet naar één tabel die later geïnterpreteerd kan worden door de algoritmes. Om dit te doen is het eerst belangrijk om te weten te komen waar de variabelen, die voor acuut nierfalen van belang zijn, zich bevinden. Uit onderzoek van Hsu (2021), waar een soortgelijk model is ontwikkeld voor het detecteren van acuut nierfalen, blijkt dat het gebruiken van variabelen zoals leeftijd, gender, etniciteit, labresultaten (stofjes in het bloed, waaronder creatinine, ureum, hemoglobine, etc.) en zaken zoals bloeddruk allemaal zijn meegenomen in het ontwikkelen van het model, wat uiteindelijk heeft geleid tot een hoge accuraatheid van 0.96. In het model van Hsu (2021), zijn uiteindelijk 38 variabelen verwerkt. In dit model zullen er echter veel minder variabelen gebruikt worden, vanwege de zogenaamde ‘vloek van dimensionaliteit’ die stelt dat het toevoegen van té veel variabelen leidt tot een afname van de prestatie van machine learning modellen (Zurada et. al., 1994). De variabelen die in dit model gebruikt zullen worden en hun locatie zijn in tabel 1 genoteerd.

Variabele	Locatie
Leeftijd	DOB (patients.csv) - Admittime (admissions.csv)
Diagnose	Diagnosis (admissions.csv) & ICD9_Code (diagnosis_icd.csv)
Serum creatinine	Itemid, Valuenum (labevents.csv)
Ureum	Itemid, Valuenum (labevents.csv)
Urine output	Itemid, Valuenum (outputevents.csv)

Alle benodigde bestanden: *outputevents.csv*, *labevents.csv*, *admissions.csv*, *diagnosis\_icd.csv*, *patients.csv*, *admissions.csv* (en de dictionaries: *d\_icd\_diagnoses.csv*, *d\_items.csv*, *d\_labitems.csv*)

Tabel 2: een overzicht van alle variabelen en hun locaties binnen de dataset.

Zoals eerder al is benoemd, is het voor het creëren van een machine learning model eerst belangrijk om een doelvariabele te selecteren. In dit model zal deze variabele weergeven of een patiënt wel of geen acuut nierfalen diagnose heeft. Aangezien een patiënt alleen maar wel of geen acuut nierfalen kan hebben, zal het een boolean zijn, waarbij *false* (0) betekent dat er geen diagnose is van acuut nierfalen en *true* (1) betekent dat er wel een diagnose is van acuut nierfalen.

Voor dit gedeelte zijn de volgende libraries nodig: *pandas*, *time*, *dateutil* en *math*.

De eerste stap bij het verwerken van de data is het selecteren van alle patiënten met acuut nierfalen. Dit is een simpele stap die uitgevoerd wordt door uit een tabel met alle gestelde diagnoses, de patiënten met een acuut nierfalen-gerelateerde diagnosis op te slaan in een nieuwe lijst genaamd 'patients'.

```
# Select all diagnoses events
df = pd.read_csv('/content/drive/MyDrive/MIMIC/DIAGNOSES_ICD.csv')

# Manually selected AKI related codes
aki_codes = ["66930", "66932", "66934", "5845", "5846", "5847", "5848", "5849"]

# Select all AKI related diagnoses
aki = df.loc[df["ICD9_CODE"].isin(aki_codes)]

# Select all patients with AKI related diagnosis
patients = []
for index, row in aki.iterrows():
    patients.append(row['SUBJECT_ID'])
```

Afbeelding 3: Een overzicht van de relevante code voor het selecteren van patiënten met acuut nierfalen

Als volgt worden de variabelen serum creatinine, ureum en het urine gehalte uit de dataset geëxtraheerd. Het urine gehalte wordt als eerst geselecteerd, door het *outputevents.csv* bestand te lezen en hieruit alle rijen die in de kolom *Itemid* de waarde '43175' bevatten op te slaan en overige informatie te verwijderen. Deze waarde is gelinkt aan het urine gehalte. De LOINC-code van de rij uit de 'dictionary' van de dataset van item '43175' komt namelijk overeen met de LOINC-code van het urine gehalte. De waarden van de urine gehaltes van patiënten wordt vervolgens toegevoegd aan de *data* tabel, waar alle data die uiteindelijk aan het model wordt toegevoegd wordt opgeslagen.

```
for index, row in out.iterrows():
    new = [row['SUBJECT_ID'], row['HADM_ID'], 43175, 0, -1, -1, row["VALUE"]]
    data.loc[len(data.index)+1] = new
```

Afbeelding 4: Een overzicht van de relevante code voor het selecteren van de urine gehaltes van patiënten

Daarna worden de waarden voor *serum creatinine* en *ureum* op een soortgelijke manier geselecteerd. De onderstaande code selecteert uit de kolom *Itemid* de waardes van de markers, en voegt deze toe aan een nieuwe kolom van de marker en koppelt de waarde van de marker aan de bijbehorende patiënt. De tabel wordt dus als het ware met een kwartslag omgedraaid.

```
for i in markers:
    for index, row in data.iterrows():
        if row["ITEMID"] == i:
            data.loc[data["HADM_ID"] == row["HADM_ID"], i] = row["VALUENUM"]
```

Afbeelding 5: Een overzicht van de relevante code voor het selecteren van de urine gehalten van patiënten

De volgende transformatie is het berekenen van de leeftijd van een patiënt bij opname in het ziekenhuis. Om hun privacy te beschermen, zijn de geboortedatum en het moment dat de patiënten zijn opgenomen in het ziekenhuis in de tijd verschoven met een willekeurig getal. Deze verschuivingen zijn echter even groot, wat betekent dat de leeftijd van de patiënt is af te leiden aan de hand van een simpele berekening: *datum van opname - geboortedatum*. Om deze berekening uit te voeren is het eerst belangrijk om ervoor te zorgen dat deze gegevens in dezelfde tabel staan en dat de datums met elkaar vergeleken kunnen worden, zodat de leeftijd van de patiënt uiteindelijk berekend kan worden.

```
# Register time of birth in data table
for index, row in pat.iterrows():
    data.loc[data['SUBJECT_ID'] == row['SUBJECT_ID'], 'DOB'] = row['DOB']

# Register time of admission in data table
for index, row in adm.iterrows():
    data.loc[data['SUBJECT_ID'] == row['SUBJECT_ID'], 'ADMITTIME'] = row['ADMITTIME']

# Register age in patients table
for index, row in data.iterrows():
    age = rdelta = relativedelta(datetime.strptime(row['ADMITTIME'], '%Y-%m-%d %H:%M:%S').date(), datetime.strptime(row['DOB'], '%Y-%m-%d %H:%M:%S').date())

    if age.years > 100:
        age.years = 90

    data.loc[data['SUBJECT_ID'] == row['SUBJECT_ID'], 'AGE'] = age.years
```

Afbeelding 6: Een overzicht van de relevante code voor het berekenen van de leeftijd van patiënten

De laatste stap bij het proces van data transformatie is het opzetten van de doelvariabele. Dit wordt simpelweg gedaan door in de *data* tabel alle mensen die in de lijst met patiënten met acuut nierfalen staan (*patients*) op te zoeken en de waarde *true* (1) toe te wijzen in de nieuwe kolom AKI. De overige mensen krijgen de waarde *false* (0) toegewezen.

```
data["AKI"] = 0
data.loc[data["SUBJECT_ID"].isin(patients), "AKI"] = 1
```

Afbeelding 7: Een overzicht van de relevante code voor het opzetten van de doelvariabele



### 1.3: Modelselectie

Het volgende gedeelte zal het proces van modelselectie bij een machine learning algoritme beschrijven. Een binair classificatiemodel kan op verschillende manieren getraind worden, zo bestaan er allerlei voorgebouwde algoritmes die op verschillende wijzen werken en die allemaal als doel hebben om een voorspelling te maken. Door al deze soorten modellen uit te testen en hun prestaties met elkaar te vergelijken kan er uiteindelijk één model worden uitgekozen dat het beste werkt.

Voor het volgende gedeelte wordt het bestand `patient_data.csv` gebruikt. Dit is een subset van de dataset bestaande uit 3870 patiënten in totaal. Dit bestand is te vinden op github: [https://github.com/santosvdw/pws/blob/main/patient\\_data.csv](https://github.com/santosvdw/pws/blob/main/patient_data.csv). Voor dit gedeelte zijn de volgende libraries nodig: `pandas`, `numpy`, `matplotlib`, `sklearn`, `imblearn` en `tensorflow`.

Voordat de modellen getraind kunnen worden, wordt de beschikbare data gesplitst in drie groepen: een training, test en validatie set. Daarnaast wordt er bij de trainingset gebruik gemaakt van 'oversampling' om het aantal patiënten met en zonder acuut nierfalen even groot te maken. Dit helpt bij het trainen van het model.

Na het trainen van elk model zullen de accuraatheid en de ROC curve geplot worden. Deze twee indicatoren zullen uiteindelijk helpen om te bepalen welk model de beste prestaties levert. De onderstaande codes weergeven hoe deze tot stand komen.

```
# False positives and true positive rates
fpr, tpr, _ = metrics.roc_curve(y_test, y_pred)

# Calculate AUC
auc = metrics.roc_auc_score(y_test, y_pred)

# Plot ROC curve
plt.plot(fpr,tpr,label="AUC="+str(auc))
plt.title("*Name of used model*")
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.legend(loc=4)
plt.show()
```

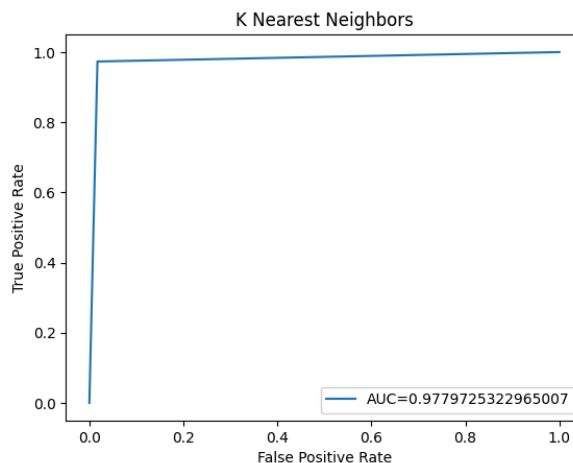
Afbeelding 8: Een overzicht van de relevante code voor het weergeven van de ROC curve

```
print(classification_report(y_test, y_pred))
```

Afbeelding 9: Een overzicht van de relevante code voor het weergeven van de prestatie van een model

Het eerste model dat getraind wordt is het K-Nearest Neighbors (KNN) model. Dit model neemt als argument een volledig getal tussen 1 en  $\infty$ . In dit geval wordt als argument het getal 1 gegeven.

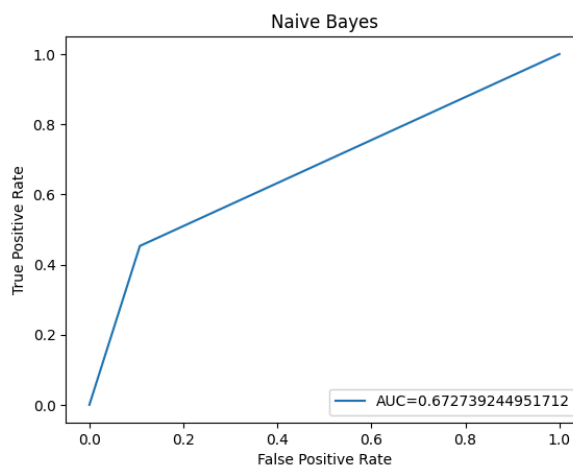
n=1				
	precision	recall	f1-score	support
0	0.99	0.98	0.99	2680
1	0.96	0.97	0.97	1190
accuracy			0.98	3870
macro avg	0.97	0.98	0.98	3870
weighted avg	0.98	0.98	0.98	3870



Afbeelding 10: De prestaties van het KNN model bij n=1      Grafiek 1: De ROC curve van het KNN model

Het volgende model dat getraind wordt is het Naive Bayes (NB) model.

	precision	recall	f1-score	support
0	0.79	0.89	0.84	2680
1	0.65	0.45	0.53	1190
accuracy			0.76	3870
macro avg	0.72	0.67	0.69	3870
weighted avg	0.74	0.76	0.74	3870




Afbeelding 11: De prestaties van het NB model

Grafiek 2: De ROC curve van het NB model

Het volgende model dat getraind wordt is het Logistic Regression model.

	precision	recall	f1-score	support
0	0.82	0.81	0.82	2680
1	0.59	0.60	0.60	1190
accuracy			0.75	3870
macro avg	0.71	0.71	0.71	3870
weighted avg	0.75	0.75	0.75	3870




Afbeelding 12: De prestaties van het Logistic Regression model

Grafiek 3: De ROC curve van het Logistic Regression model

Het vierde model dat getraind wordt is het Support Vector Machine (SVM) model.


	precision	recall	f1-score	support
0	0.84	0.83	0.83	2680
1	0.62	0.64	0.63	1190
accuracy			0.77	3870
macro avg	0.73	0.73	0.73	3870
weighted avg	0.77	0.77	0.77	3870



Afbeelding 13: De prestaties van het SVM model

Grafiek 4: De ROC curve van het SVM model

Het laatste model dat getraind wordt is het Neural Network (NN) model.



Grafiek 5: De ROC curve van het NN model

Zoals eerder al benoemd worden de modellen beoordeeld op basis van hun AUC. Dit is een getal tussen 0 en 1 waarbij 0 het laagst en 1 het hoogste is. Een rangschikking van de AUC waarden van de vijf modellen is te zien in tabel 2.

Rang	Model	AUC
1	K Nearest Neighbors	0.98
2	Neural Network	0.83
3	Support Vector Machine	0.73
4	Logistic Regression	0.71
5	Naive Bayes	0.67

Tabel 3: Een overzicht van de vijf getrainde modellen, gerangschikt op AUC van hoog naar laag

Uit tabel 2 is af te lezen dat het K Nearest Neighbors model de hoogste AUC heeft, namelijk 0.98. Het K-Nearest-Neighbors model is dus het geselecteerde model, omdat deze de taak van binaire classificatie bij de gebruikte dataset het beste uitvoert. In tabel 3 is te zien wat er gebeurt met de prestatie van het KNN model bij waarden [1,5] van  $n$  (het argument van het KNN model). Deze 5 waarden worden als volgt met een loop berekend:

```
i = 0
while i < 5:
    i += 1
    knn_model = KNeighborsClassifier(n_neighbors=i)
    knn_model.fit(x_train, y_train)
    y_pred = knn_model.predict(x_test)
    print(f"{i}: {metrics.roc_auc_score(y_test, y_pred)}")
```

Afbeelding 14: Een overzicht van de relevante code voor het berekenen van de AUC waarden voor  $n = [1,5]$

$n$	AUC
1	0.98
2	0.91
3	0.87
4	0.84
5	0.82

Tabel 4: Een overzicht van de AUC waarden voor  $n = [1,5]$

Zoals in tabel 3 te zien is, neemt de AUC af als  $n$  toeneemt. Hieruit is dus te concluderen dat het KNN model met  $n=1$  het best mogelijke model is voor het diagnosticeren van acuut nierfalen met de huidige dataset.

## 1.4: Model implementatie

Voor dit gedeelte is de volgende library nodig: `joblib`.

Nu dat het beste model uitgekozen is, kan deze klaar worden gemaakt voor implementatie, waardoor het door anderen gebruikt zal kunnen worden. Dit kan simpelweg gedaan worden door het model te downloaden en vervolgens in een andere omgeving te laden. Dit kan als volgt worden gedaan:

```
joblib.dump(knn_model, 'aki_diagnoser.joblib')
```

Afbeelding 15: De code die het machine learning model download

Deze regel code zorgt ervoor dat het machine learning model gedownload wordt naar de lokale machine. Dat maakt het dus makkelijker om het model in een andere omgeving weer uit te voeren. Om het model dan weer te laden is de volgende regel code nodig:

```
model = joblib.load('aki_diagnoser.joblib')
```

Afbeelding 16: De code die het machine learning model laadt

Vervolgens is het ook erg makkelijk om voorspellingen te doen met het model. Het enige wat de gebruiker hoeft te doen is een lijst met het serum creatinine gehalte, de ureum concentratie, de urine output en de leeftijd van de patiënt als input te geven.

```
prediction = model.predict([[1.5, 11, -1, 75]])  
print(prediction)
```

Afbeelding 17: Een weergave van de code die benodigd is om voorspellingen te doen met het model

Het model kan uiteindelijk bijvoorbeeld worden vastgekoppeld aan een user interface, zodat artsen makkelijk informatie kunnen invullen om snel een inzicht te krijgen in de toestand van hun patiënten.

## **Deel 2: Verder dan de code: Begrijpen hoe machine learning de zorg kan transformeren**

In dit deel van het verslag wordt de fascinerende wereld van machine learning behandeld in de gezondheidszorg, een zaak die zowel hoopvol als complex is. Er wordt namelijk een tijdperk betreden waarin technologie en geneeskunde samensmelten op manieren die enkele decennia geleden nog ondenkbaar waren. Er wordt verkend hoe deze geavanceerde technologie de potentie heeft om de manier waarop ziekten worden gediagnosticeerd en behandeld te revolutionariseren, terwijl ook de diepere ethische en praktische vraagstukken aangepakt worden die deze innovaties met zich meebrengen.

Van de stille gangen van ziekenhuizen tot de bruisende onderzoekscentra, machine learning is niet langer een verre toekomstdroom, maar een realiteit die de gezondheidszorg transformeert. Eerst wordt er een blik geworpen op hoe nieuwe diagnostische tools, aangedreven door machine learning, de precisie en snelheid van medische diagnoses verbeteren, levens redden en nieuwe mogelijkheden openen voor vroegtijdige interventie.

Met grote kracht komt echter grote verantwoordelijkheid. In het tweede deel van dit profielwerkstuk wordt er gekeken naar de ethische implicaties van machine learning in de zorg. Hier worden de complexe vraagstukken rond privacy ontrafeld, gegevensbeveiliging en de morele dilemma's die ontstaan wanneer machines beslissingen nemen die voorheen door mensen werden genomen.

Tot slot wordt er onderzoek gedaan naar de praktische kant van de implementatie van machine learning in de klinische praktijk. Er wordt onderzocht welke uitdagingen en kansen die medische professionals tegenkomen bij het integreren van deze geavanceerde technologieën in hun dagelijkse werk.

# 1: De impact van een nieuwe diagnostische tool

## *1.1 Hoe kan het gebruik van machine learning in de diagnostiek de medische besluitvorming ondersteunen?*

Het gebruik van machine learning in de medische diagnostiek kan de besluitvorming in de gezondheidszorg aanzienlijk ondersteunen, zoals blijkt uit modellen die vergelijkbaar zijn met het model dat is ontwikkeld. Er zijn hier verschillende redenen voor, omdat het nou eenmaal een vorm van kunstmatige intelligentie is die snel en nauwkeurig grote hoeveelheden data kan analyseren. Dit leidt tot verbeteringen in verschillende aspecten in de patiëntenzorg. (Naveed, 2023).

Om te beginnen is een sleutelvoordeel van machine learning, zoals geïllustreerd in het ontwikkelde model, de verbeterde diagnostische nauwkeurigheid: machine learning-algoritmen kunnen grote hoeveelheden medische gegevens uit datasets analyseren om patronen te identificeren, om anomalieën op te sporen en ziekten te diagnosticeren. Dit kan leiden tot een snellere en nauwkeurigere diagnose, wat vooral belangrijk is voor ziekten zoals kanker, waar vroege detectie cruciaal is voor de behandeling. Maar ook dus bijvoorbeeld acuut nierfalen hoort hierbij, een medische aandoening die snel en onverwachts op kan treden. (Satapathy et al., 2023)

Verder kunnen de machine learning modellen dienen als ondersteuning bij behandelingsplannen. Machine learning kan zorgprofessionals helpen bij het voorspellen van ziekteprogressie en het begeleiden van behandelplannen. Dit leidt tot meer gerichte en effectieve interventies, waardoor de kans op succesvolle uitkomsten toeneemt (Farid, 2023).

De meer gerichte behandelingen zijn natuurlijk verschillend per patiënt, dus personalisatie van patiëntenzorg komt er ook bij kijken. Door het gebruik van machine learning in de diagnostiek kunnen behandelingen meer gepersonaliseerd worden. Machine learning-algoritmen kunnen patiëntspecifieke gegevens analyseren om aanbevelingen te doen die specifiek zijn afgestemd op de individuele behoeften van de patiënt. Dit allemaal kan snel worden gedaan, want ook een groot kenmerk van het gebruik van machine learning is de efficiëntie in gezondheidszorgsystemen.

Machine learning modellen vergelijkbaar met het in dit onderzoek ontwikkelde model kunnen dus helpen bij het optimaliseren van ziekenhuisoperaties, het vergemakkelijken van administratieve taken en het verbeteren van de toewijzing van middelen. Dit kan leiden tot kostenbesparingen en een betere patiëntervaring (Nsier, 2023).

Ten slotte speelt machine learning, zoals geïmplementeerd in het in dit onderzoek ontwikkelde model, een cruciale rol in risicobeoordeling en preventie, omdat dit een hedendaags en toekomstig punt van belang is.

Het is dus een grote investering als er wordt gekeken naar toekomstige problematiek. Machine learning-algoritmen kunnen worden gebruikt om risicofactoren voor bepaalde aandoeningen te identificeren, waardoor preventieve maatregelen kunnen worden genomen voordat de ziekte zich ontwikkelt (Naveed, 2023).

Maar, artificial intelligence binnen in de zorg is geen “toekomstig mysterie”: het wordt nu al gebruikt op verschillende vakgebieden. KNO arts en CMIO van Dijkland Ziekenhuis Marein van der Torn benoemt dit in een interview (in de bijlage is het audiobestand van dit interview te vinden): *“Er wordt al in een aantal ziekenhuizen in Nederland bij het ontslagmanagement van de intensive care gebruikgemaakt van dergelijke technieken. De intensive care bedden zijn heel schaars. Welke patiënt kan er morgen misschien van de intensive care af? Want dan hebben we weer een bed vrij waardoor we anderen kunnen aannemen uit de regio.”* Het gebruik van kunstmatige intelligentie maakt de taak van het inschatten van de staat van patiënten in de intensive care dus veel makkelijker, door de data van de patiënt te analyseren en in te schatten wanneer hij ontslagen kan worden.

## *1.2 Wat is de potentiële impact van deze technologie op de patiëntenzorg en behandelingsuitkomsten?*

Machine learning technologieën zoals het in dit onderzoek ontwikkelde model hebben een aanzienlijke impact op de gezondheidszorg. Een onderzoek gericht op de geestelijke gezondheidszorg toonde aan dat machine learning-modellen effectief zijn in het voorspellen van de respons van patiënten op behandelingen. Deze modellen bieden een krachtige tool voor het vroegtijdig identificeren van patiënten met een verhoogd risico op ongewenste behandelingsresultaten, wat belangrijke implicaties heeft voor het verbeteren van de zorgplanning en het tijdig ingrijpen om de behandelingsresultaten te optimaliseren (Van Mens et al., 2022).

In de spoedeisende hulp is machine learning ook gebruikt om kritieke zorguitkomsten bij patiënten met borstpijn te voorspellen. Dit is zeker van belang bij het in dit onderzoek ontwikkelde model, omdat het bij het opsporen van acuut nierfalen het van belang is om tijdig op de hoogte te zijn. De ontwikkelde machine learning-modellen bleken accurater dan traditionele methoden, wat wijst op het potentieel van machine learning om de besluitvorming in noodsituaties te verbeteren en de patiëntenzorg te optimaliseren (Wu et al., 2021).



Een andere studie in de oncologie integreerde patiëntgerapporteerde uitkomstmaten met elektronische gezondheidsdossiers om acute zorgevenementen te voorspellen. De resultaten toonden aan dat het combineren van deze gegevens in machine learning-modellen de nauwkeurigheid van het voorspellen van risico's op acute zorgevenementen verbeterd, wat het belang van patiëntgerichte zorg en proactieve zorgplanning benadrukt (Roberts et al., 2023).

Ten slotte is machine learning toegepast in de voorspelling van klinische uitkomsten na een eerste ischemische beroerte. Deze toepassing van machine learning heeft aangetoond dat het mogelijk is om verschillende klinische uitkomsten, zoals functioneel herstel en cognitieve functie, nauwkeurig te voorspellen, wat het potentieel van machine learning om de patiëntenzorg te personaliseren en behandelingsstrategieën na een beroerte te verbeteren onderstreept (Fast et al., 2023).

Maar met positieve impact zijn er ook dergelijke risico's. Geriatriest Johan Schuijtemaker geeft hier zijn kijk op: *“Waar ik het risico in zie, is dat zoveel data ook weer gegenereerd wordt, dat dokters die allemaal ook weer moeten controleren. Gaan we vertrouwen op machine learning en wat er uit komt, of zullen wij zelf daar altijd nog naar moeten kijken? Wie is er verantwoordelijk?”* (het volledige interviewtranscript is te vinden in de bijlage). Marein van der Torn vindt dat er dan wel een dergelijk onderscheid gemaakt moet worden over op wie deze risico's ook echt een impact hebben. *“In het ziekenhuis hebben we snijders en beschouwers”*, aldus van der Torn. Met de 'snijders' worden de zorgprofessionals die bijvoorbeeld opereren bedoeld, met de 'beschouwers' worden vaker doktoren die gesprekken houden en onderzoek doen bedoeld. De machine learning technieken die in de zorg worden gebruikt, zullen meer impact hebben op 'beschouwers', omdat ze de taken van de 'snijders' (nog) niet altijd kunnen overnemen.

## 2: De ethische implicaties van machine learning in de zorg

### 2.1: *Wat zijn de ethische kwesties rond het gebruik van machine learning in de gezondheidszorg?*

Hoewel machine learning modellen zoals net beschreven veel positieve kanten hebben, zijn er ook ethische kwesties rond het gebruik van machine learning in de gezondheidszorg oftewel Machine Learning Healthcare Applications (ML-HCA's), en deze zijn veelzijdig en complex. ML-HCA's omvatten een breed scala aan toepassingen in de gezondheidszorg, variërend van diagnostische hulpmiddelen tot gepersonaliseerde behandelingsplannen. De aanzienlijke voordelen zoals verbeterde diagnostische nauwkeurigheid en efficiëntie in de zorg brengen dus wel ethische uitdagingen met zich mee. Denk aan privacy, gegevensbeveiliging, algoritmische bias en de verantwoordelijkheid voor besluitvorming. Een onderzoek van Danton Char, Michael Abràmoff en Chris Feudtner uit 2020 bespreekt een aantal van deze ethische kwesties.

#### Privacy en gegevensbeveiliging

De bescherming van patiëntgegevens is een cruciale zorg bij ML-HCA's. Deze systemen vereisen toegang tot grote hoeveelheden persoonlijke en medische gegevens, wat vragen oproept over de verzameling, opslag, gebruik en delen van deze gegevens. Het waarborgen van de privacy van patiënten vereist strikte naleving van gegevensbeschermingswetten en -regelgeving, evenals het implementeren van robuuste beveiligingsmaatregelen om datalekken en misbruik te voorkomen.

#### Algoritmische bias en discriminatie

Er bestaat een risico dat machine learning-modellen, indien niet zorgvuldig ontworpen en getraind, vooroordelen kunnen bevatten die leiden tot discriminatie. Dit kan vooral problematisch zijn als de trainingsdata niet representatief zijn voor de diversiteit van de patiëntenpopulatie, wat kan resulteren in minder nauwkeurige of eerlijke uitkomsten voor bepaalde groepen. Om dit te voorkomen is het dus belangrijk om veelzijdige datasets te gebruiken.

#### Verantwoordelijkheid en aansprakelijkheid

Het bepalen van de verantwoordelijkheid bij fouten of onnauwkeurigheden in ML-HCA's is complex. Er rijzen vragen over wie aansprakelijk is bij fouten - de ontwikkelaars van het algoritme, de zorgverleners die het gebruiken, of een andere partij. Dit vereist duidelijke richtlijnen en regelgeving om verantwoordelijkheid en aansprakelijkheid te definiëren. Overheden lopen momenteel nog erg achter op het gebied van dergelijke regelgeving. De Europese Unie is voorloper op het gebied van richtlijnen en regelgeving op het gebied van

machine learning algoritmes, maar regels met betrekking tot ML-HCA's zijn momenteel nog niet tot stand gekomen.

### Transparantie en uitlegbaarheid

Veel machine learning-modellen, vooral diepe neurale netwerken, zijn vaak 'black boxes', wat betekent dat hun besluitvormingsprocessen niet transparant of gemakkelijk te begrijpen zijn. Hierbij komen er kwesties kijken over hoe patiënten en zorgverleners de uitkomsten van deze modellen kunnen vertrouwen en begrijpen, en benadrukt de noodzaak van transparantie en uitlegbaarheid in machine learning-systemen.

### Toestemming en autonomie van de patiënt

Er zijn zorgen over hoe en in welke mate patiënten geïnformeerd en betrokken worden bij het gebruik van hun gegevens voor ML-HCA's. Het respecteren van de autonomie van de patiënt vereist dat zij volledig geïnformeerd worden en toestemming geven voor het gebruik van hun gegevens, wat essentieel is voor het behoud van vertrouwen in ML-HCA's. Voor het creëren van sommige medische datasets, zoals de MIMIC-III dataset, is er afgezien van de vereiste voor toestemming van de individuele patiënt, omdat alle informatie geanonimiseerd is volgens de Amerikaanse Health Insurance Portability and Accountability Act (HIPAA) richtlijnen. Zulke richtlijnen, die de privacy van patiënten waarborgen, nemen dus een deel van de autonomie van patiënten weg, maar dragen bij aan hun privacy, wat erg belangrijk is bij het ethische proces rondom het ontwikkelen van een ML-HCA (Johnson, 2016).

### Onduidelijkheid bij de herkomst van de data

Een ander belangrijk aspect is dat er soms niet helemaal met zekerheid gezegd kan worden welke data en hoe deze data tot stand is gekomen. Geriatriest Johan Schuijtemaker gaf hier een voorbeeld van: *“Bij de ethische kwesties zie ik het probleem van dat je niet goed weet hoe dat apparaat aan de data komt, dus via welk algoritme, want het zijn niet de medici en medische wetenschappers die dat erin hebben gestopt maar uiteindelijk zijn dat grote tech bedrijven. Die bedrijven maken keuzes, en dat kan ook ten goede wil zijn, maar die maken dus wel keuzes, die eigenlijk veel meer zouden moeten liggen bij medische professionals of bij de overheid.”*

Deze ethische kwesties vereisen zorgvuldige overweging en management om ervoor te zorgen dat ML-HCA's op een verantwoorde en ethisch verantwoorde manier worden ingezet in de gezondheidszorg.

### Wetgeving

Wetgeving omtrent machine learning in de gezondheidszorg is een complex en zich snel ontwikkelend gebied. Uit verschillende rapporten en studies blijkt dat er in meerdere rechtsgebieden behoefte is aan juridische hervormingen om de uitdagingen en problemen die gepaard gaan met gezondheidsgerelateerde kunstmatige intelligentie (AI) aan te pakken (BMJ Open, 2021). Dit omvat vragen over de veiligheid en effectiviteit van AI-tools, contractuele en onrechtmatige aansprakelijkheid voor schade veroorzaakt door AI, en ethische kwesties zoals AI-veiligheid, vooroordelen en geïnformeerde toestemming die juridische reacties kunnen vereisen (Price & Cohen, 2019; Vayena et al., 2018). Maar het is nog niet heel concreet, omdat de ontwikkeling van artificial intelligence enorm snel gaat en zorgt voor onduidelijkheid en onzekerheid met grenzen op ethisch gebied. Dus wat betreft of de ethische implicaties kunnen worden opgelost op juridisch gebied, is er zeker nog ruimte voor ontwikkeling.

## *2.2 Hoe kan de privacy van patiëntgegevens worden gewaarborgd bij het gebruik van machine learning-algoritmen in ziekenhuizen?*

Het probleem van de privacy kan echter wel worden aangepakt. De privacy van patiëntgegevens bij het gebruik van machine learning-algoritmen in ziekenhuizen kan effectief worden gewaarborgd door het toepassen van federatief leren, een innovatieve benadering die zowel de privacy beschermt als waardevolle inzichten uit gegevens haalt. Federatief leren is een methode waarbij machine learning-modellen worden getraind over meerdere gedecentraliseerde datasets, zonder dat deze datasets daadwerkelijk worden gedeeld of verplaatst. In plaats van de gevoelige patiëntgegevens naar een centrale locatie te sturen, wordt het machine learning-model naar de data gebracht.

In de praktijk betekent dit dat elk deelnemend ziekenhuis zijn eigen dataset lokaal houdt en het model traint op deze lokale data. Vervolgens wordt alleen het geüpdatete model, en niet de onderliggende patiëntgegevens, gedeeld met andere deelnemende instellingen. Dit zorgt ervoor dat een gezamenlijk model wordt ontwikkeld dat leert van alle beschikbare data, terwijl de privacy van de patiënten behouden blijft. Deze methode is bijzonder effectief in scenario's waar privacy een grote zorg is, zoals in de gezondheidszorg.

Deze aanpak van federatief leren is succesvol toegepast in verschillende onderzoeken, waaronder het onderzoek van Dou et al. (2021), waarbij het werd gebruikt voor het diagnosticeren van COVID-19 gerelateerde afwijkingen in CT-scans. Door federatief leren konden ziekenhuizen snel reageren op de pandemie en samenwerken aan het ontwikkelen van een krachtig diagnostisch hulpmiddel, zonder de privacy van patiënten in gevaar te brengen.

### 3: Het gebruiken van een nieuwe tool door doctoren

#### *3.1 Wat zijn uitdagingen bij het implementeren van machine learning in ziekenhuizen?*

Bij het implementeren van machine learning in ziekenhuizen komen verschillende uitdagingen naar voren. Een van de belangrijkste uitdagingen is de integratie van machine learning-systemen met bestaande gezondheidsinformatiesystemen, vaak aangeduid als 'legacy-systemen'. Deze legacy-systemen zijn oudere IT-infrastructuren of software die al lang in gebruik zijn binnen ziekenhuizen. Ze zijn vaak niet ontworpen om te integreren met de nieuwste technologieën, waaronder geavanceerde machine learning-toepassingen. Dit kan leiden tot technische en operationele problemen, zoals compatibiliteitsproblemen en moeilijkheden bij het updaten of aanpassen van deze systemen aan nieuwe eisen (Mullie et al., 2023).

Een andere uitdaging is de kwaliteit en beschikbaarheid van data. Machine learning-modellen vereisen grote hoeveelheden nauwkeurige en goed gelabelde data om effectief te zijn. In de praktijk kan het echter moeilijk zijn om toegang te krijgen tot voldoende kwalitatieve data, vooral in ziekenhuizen waar data vaak verspreid en ongestructureerd is opgeslagen.

Verder speelt de kwestie van privacy en gegevensbeveiliging een grote rol, zoals al eerder is benoemd. Ziekenhuizen moeten ervoor zorgen dat patiëntgegevens beschermd worden en voldoen aan privacywetgeving, zoals bijvoorbeeld de HIPAA richtlijnen in de Verenigde Staten. HIPAA stelt normen voor de bescherming van gevoelige patiëntgegevens en vereist dat zorgverleners en andere betrokken partijen passende administratieve, fysieke en technische veiligheidsmaatregelen nemen om de privacy van patiëntgegevens te waarborgen. Dit vereist strikte beveiligingsmaatregelen en zorgvuldige omgang met patiëntgegevens, wat een extra laag van complexiteit toevoegt aan de implementatie van machine learning (Mullie et al., 2023).

Als laatste is er de uitdaging van het verkrijgen van acceptatie en vertrouwen van zorgverleners en patiënten. Het succes van machine learning in ziekenhuizen hangt niet alleen af van de technologie zelf, maar ook van hoe goed zorgverleners en patiënten de technologie begrijpen en vertrouwen. Dit vereist adequate training, onderwijs en betrokkenheid bij het implementatieproces.

### *3.2 Welke factoren kunnen van invloed zijn op de acceptatie door medisch personeel?*

Machine learning heeft dus, ondanks een aantal complexere kanten, veel voordelen. Maar, dan is er nog wel het probleem van acceptatie van medisch personeel. De acceptatie van machine learning door medisch personeel in ziekenhuizen wordt beïnvloed door diverse factoren. Ten eerste speelt de vertrouwdheid van het personeel met digitale technologieën een cruciale rol. Medewerkers die comfortabel zijn met het gebruik van geavanceerde technologieën zullen waarschijnlijk opener staan voor het integreren van machine learning in hun werk.

Daarnaast is de waargenomen relevantie en effectiviteit van machine learning-toepassingen voor hun klinische taken van groot belang. Als medisch personeel gelooft dat deze technologieën hun werk kunnen verbeteren of vereenvoudigen, neemt de kans op acceptatie toe, zoals waargenomen in het onderzoek van Alshurideh en Kurdi (2022).

Een andere belangrijke factor is de beschikbaarheid van kwalitatieve training en ondersteuning. Goede educatieve programma's en toegankelijke technische ondersteuning kunnen helpen om eventuele weerstand tegen nieuwe technologieën te verminderen en het personeel vertrouwen te geven in het gebruik ervan (Lu et al., 2020).

Tot slot is de manier waarop de invoering van machine learning wordt gemanaged en gecommuniceerd binnen de ziekenhuisorganisatie van essentieel belang. Een duidelijke en transparante communicatiestrategie over de voordelen en doelen van machine learning kan helpen om een positieve houding te creëren en de acceptatie onder het medisch personeel te bevorderen.

Volgens Johan Schuijtemaker is acceptatie echter te verkrijgen door *“klein te beginnen en het personeel vanaf het begin meenemen.”* Ook voegt hij toe: *“Laat ze meedenken over welke meerwaarde het heeft.”* Maar, *“onder druk wordt er meer geaccepteerd”*, zegt Marein van der Torn. In de huidige wereld van nu, waar kunstmatige intelligentie zich zo snel ontwikkelt, onder andere in de zorg, zal het personeel het sneller accepteren. Het is dan wel belangrijk dat er duidelijkheid is welk deel van de baan wordt verholpen als er machine learning technieken worden toegepast om taken over te nemen. Als de meer administratieve taken die veel tijd innemen worden overgenomen, is dat juist beter, omdat er dan meer tijd is om oprecht met de patiënt in gesprek te gaan, volgens van der Torn.

### *3.3 Wat voor soort training hebben medische professionals nodig om effectief gebruik te kunnen maken van machine learning-tools in de klinische praktijk?*

Om effectief gebruik te kunnen maken van machine learning-tools in de klinische praktijk, is het essentieel dat medische professionals goed zijn voorbereid. Deze voorbereiding gaat verder dan alleen het aanleren van technische vaardigheden; het vereist een nauwkeurige benadering van training.

Een fundamenteel begrip van machine learning is cruciaal. Medische professionals moeten niet alleen weten hoe deze tools werken, maar ook inzicht hebben in de onderliggende principes van de algoritmen, hun trainingsprocessen en de beperkingen ervan. Deze kennis stelt hen in staat om de mogelijkheden en grenzen van deze technologieën te begrijpen.

Naast theoretische kennis is praktische ervaring met machine learning-tools onmisbaar. Dit betekent dat medische professionals moeten leren hoe ze deze tools kunnen integreren in hun dagelijkse praktijk, van het bedienen van de software tot het interpreteren van de resultaten. Het is belangrijk dat ze leren hoe ze de output van deze systemen kunnen combineren met hun eigen klinische expertise.

Een kritische blik ontwikkelen is een ander belangrijk aspect van de training. Medische professionals moeten leren om de resultaten van machine learning-systemen kritisch te beoordelen, rekening houdend met de context van elke patiënt en andere beschikbare klinische informatie. Dit helpt hen om een evenwicht te vinden tussen technologie en menselijke besluitvorming.

Ten slotte is het van cruciaal belang dat de training aandacht besteedt aan ethische aspecten, zoals patiëntprivacy, gegevensbeveiliging en het voorkomen van bias in machine learning-modellen. Dit zorgt ervoor dat medische professionals niet alleen technisch bekwaam zijn, maar ook ethisch verantwoord handelen in hun gebruik van machine learning (Nagy et. al., 2022).

Deze geïntegreerde aanpak van training, die zowel technische vaardigheden als ethische en praktische overwegingen omvat, is essentieel om medische professionals volledig uit te rusten voor het werken met machine learning in de gezondheidszorg.



# Literatuurlijst

## Literaire bronnen

1. Alshurideh, M., & Kurdi, B. (2022). Factors affecting social networks acceptance: An extension to the technology acceptance model using PLS-SEM and Machine Learning Approach. <https://doi.org/10.5267/j.ijdns.2022.8.010>
2. Biggane, A. M., Briegal, E., & Obasi, A. (2021). (BMO) Interventions for adolescent alcohol consumption in Africa: protocol for a scoping review including an overview of reviews. *Systematic Reviews*, 10(1). <https://doi.org/10.1186/s13643-021-01642-4>
3. Char, D., Abràmoff, M., & Feudtner, C. (2020). Identifying Ethical Considerations for Machine Learning Healthcare Applications. *The American Journal of Bioethics*, 20(11), 7-17. <https://doi.org/10.1080/15265161.2020.1819469>
4. Classification: ROC Curve and AUC. (z.d.). Google for Developers. <https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc>
5. Data Storage and Management in Healthcare: Options & Best practices. (z.d.). Demigos. <https://demigos.com/blog-post/data-storage-and-management-in-healthcare/>
6. Date, C.pandas (2003). *An Introduction to Database Systems* (8th ed.). Pearson. ISBN 978-0321197849.
7. Dirba, E. B. (2020). A Comparative study of data splitting algorithms for machine learning model selection. KTH ROYAL INSTITUTE OF TECHNOLOGY. <https://www.diva-portal.org/smash/get/diva2:1506870/FULLTEXT01.pdf>
8. Edelstein, C. L. (2008). Biomarkers of acute kidney injury. *Advances in Chronic Kidney Disease*, 15(3), 222-234. <https://doi.org/10.1053/j.ackd.2008.04.003>
9. Farid, Y. (2023). A Call for Guidelines and Regulatory Body in Adopting Artificial Intelligence for Plastic Surgeons. *Plastic and Reconstructive Surgery Global Open*. <https://dx.doi.org/10.1097/gox.00000000000005340>
10. Fast, L., Temuulen, U., Villringer, K., Kufner, A., Ali, H. F., Siebert, E., Huo, S., Piper, S. K., Sperber, P. S., Liman, T., Endres, M., & Ritter, K. (2023). Machine learning-based prediction of clinical outcomes after first-ever ischemic stroke. *Frontiers in Neurology*, 14. <https://dx.doi.org/10.3389/fneur.2023.1114360>
11. Hashemi-Pour, C., & Carew, J. M. (2023, 16 augustus). Reinforcement learning. Enterprise AI. <https://www.techtarget.com/searchenterpriseai/definition/reinforcement-learning>
12. ICTinformatiecentrum.nl. (2023, 16 november). Data mining | Wat is het? <https://www.ictinformatiecentrum.nl/data-analytics/data-mining>

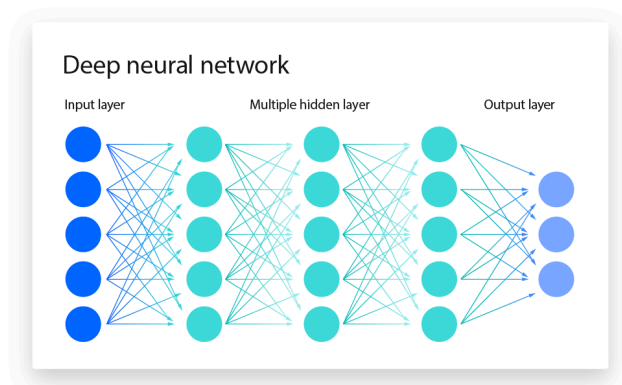
13. Johns Hopkins Medicine. (2023, July 17). Report Highlights Public Health Impact of Serious Harms From Diagnostic Error in U.S. Geraadpleegd van <https://www.hopkinsmedicine.org/news/newsroom/news-releases/report-highlights-public-health-impact-of-serious-harms-from-diagnostic-error-in-us>
14. Johnson, A., Pollard, T., & Mark, R. (2016). MIMIC-III Clinical Database (version 1.4). PhysioNet. <https://doi.org/10.13026/C2XW26>.
15. Liu, D., Shin, W.-Y., Sprecher, E., Conroy, K., Santiago, O., Wachtel, G., & Santillana, M. (2022). Machine learning approaches to predicting no-shows in pediatric medical appointment. npj Digital Medicine. <https://doi.org/10.1038/s41746-022-00594-w>
16. Lu, D.-N., Le, H.-Q., & Vu, T.-H. (2020). The Factors Affecting Acceptance of E-Learning: A Machine Learning Algorithm Approach. <https://doi.org/10.3390/EDUCSCI10100270>
17. Mellas, J. (2016). The description of a method for accurately estimating creatinine clearance in acute kidney injury. PubMed, 275, 107–114. <https://doi.org/10.1016/j.mbs.2016.02.010>
18. Mohri, M., Rostamizadeh, A., Talwalkar A., (2012) Foundations of Machine Learning, The MIT Press ISBN 9780262018258.
19. Mullie, L., Afilalo, J., Archambault, P., Bouchakri, R., Brown, K., Buckeridge, D. L., ... & Chassé, M. (2023). CODA: an open-source platform for federated analysis and machine learning on distributed healthcare data. Journal of the American Medical Informatics Association. <https://doi.org/10.1093/jamia/ocad235>
20. Naveed, M. A. (2023). Transforming Healthcare through Artificial Intelligence and Machine Learning. Pakistan Journal of Health Sciences, 4(5). <https://dx.doi.org/10.54393/pjhs.v4i05.844>
21. Nsier, H. (2023). Ethical considerations of using artificial intelligence to drive clinical decision support in pediatric medical settings. Pediatric Research. <https://dx.doi.org/10.1038/s41390-022-02452-7>
22. Pandas documentation — Pandas 2.1.4 documentation. (z.d.). <https://pandas.pydata.org/docs/index.html>
23. Price, W. N., & Cohen, I. G. (2019). Privacy in the age of medical big data. Nature Medicine, 25(1), 37–43. <https://doi.org/10.1038/s41591-018-0272-7>
24. Roberts, T., McGuire, J., Temel, J., Kamdar, M., Greer, J., & Mulvey, T. (2023). Developing machine learning algorithms incorporating patient reported outcome measures to predict acute care events among patients with cancer. Journal of Clinical Oncology, 41(16\_suppl), 1516. [https://dx.doi.org/10.1200/jco.2023.41.16\\_suppl.1516](https://dx.doi.org/10.1200/jco.2023.41.16_suppl.1516)
25. Roman, V. (2021, 7 december). How to develop a machine learning model from scratch. Medium.

- <https://towardsdatascience.com/machine-learning-general-process-8f1b510bd8af>
26. Satapathy, P., Pradhan, K., Rustagi, S., Suresh, V., Al-qaim, Z. H., Padhi, B., & Sah, R. (2023). Application of machine learning in surgery research: current uses and future directions – editorial. *Journal of Surgery Open Access*, 9(4).  
<https://dx.doi.org/10.1097/JS9.0000000000000421>
  27. Shaheen, M. (2021). Adoption of machine learning for medical diagnosis. *ScienceOpen Preprints*. <https://doi.org/10.14293/s2199-1006.1.sor-.pphmka6.v1>
  28. Stedman, C., & Hughes, A. (2021, 7 september). Data mining. *Business Analytics*.  
<https://www.techtarget.com/searchbusinessanalytics/definition/data-mining>
  29. Using Matplotlib – Matplotlib 3.8.2 documentation. (z.d.).  
<https://matplotlib.org/stable/users/index.html>
  30. Van Beek, D. (z.d.). Wat is machine learning: algoritmes, modellen, toepassingen en technieken inclusief stappenplan.  
<https://www.passionned.nl/bi/data-science/machine-learning/>
  31. Van Mens, K., Lokkerbol, J., Wijnen, B., Janssen, R., de Lange, R., & Tiemens, B. (2022). Predicting Undesired Treatment Outcomes With Machine Learning in Mental Health Care: Multisite Study. *JMIR Medical Informatics*, 10(1), e44322.  
<https://dx.doi.org/10.2196/44322>
  32. Van Moll, C., Egberts, T., Wagner, C., Zwaan, L., & Ten Berg, M. (2023). The Nature, Causes, and Clinical Impact of Errors in the Clinical Laboratory Testing Process Leading to Diagnostic Error: A Voluntary Incident Report Analysis. *Journal of Patient Safety*, 19(8), 573–579. <https://doi.org/10.1097/PTS.0000000000001166>
  33. Vayena, E., Blasimme, A., & Cohen, I. G. (2018). Machine learning in medicine: Addressing ethical challenges. *PLOS Medicine*, 15(11), e1002689.  
<https://doi.org/10.1371/journal.pmed.1002689>
  34. What are neural networks? | IBM. (z.d.).  
<https://www.ibm.com/topics/neural-networks>
  35. What is a database? (z.d.). <https://www.oracle.com/database/what-is-database/>
  36. Wikipedia contributors. (2023, 3 december). Machine learning. Wikipedia.  
[https://en.wikipedia.org/wiki/Machine\\_learning](https://en.wikipedia.org/wiki/Machine_learning)
  37. Wikipedia contributors. (2023, november 21). Sensitivity and specificity. Wikipedia.  
[https://en.wikipedia.org/wiki/Sensitivity\\_and\\_specificity](https://en.wikipedia.org/wiki/Sensitivity_and_specificity)
  38. Wu, T., Zheng, R., Lin, Z., Gong, H., & Li, H. (2021). A machine learning model to predict critical care outcomes in patient with chest pain visiting the emergency department. *BMC Emergency Medicine*, 21(1), 5.  
<https://dx.doi.org/10.1186/s12873-021-00501-8>
  39. Zheng, A. (2015) Evaluating Machine Learning Models. *Strata*.  
<https://riskcue.id/uploads/ebook/20210920085146-2021-09-20ebook085121.pdf>


40. Zurada, J. M., Marks, R. J., & Robinson, C. J. (1994). Computational intelligence: Imitating Life. Institute of Electrical & Electronics Engineers(IEEE).

### Afbeeldingen

Afbeelding 1: Een weergave van een Artificial Neural Network (IBM, z.d.). (P.8)



Afbeelding 2: Een weergave van positieve en negatieve classificaties die met de ROC curve weergegeven worden. (Wikipedia, 2023). (P.13)



Afbeelding 3: Een overzicht van de relevante code voor het selecteren van patiënten met acuut nierfalen (P.23)

```
# Select all diagnoses events
df = pd.read_csv('/content/drive/MyDrive/MIMIC/DIAGNOSES_ICD.csv')

# Manually selected AKI related codes
aki_codes = ["66930", "66932", "66934", "5845", "5846", "5847", "5848", "5849"]

# Select all AKI related diagnoses
aki = df.loc[df["ICD9_CODE"].isin(aki_codes)]

# Select all patients with AKI related diagnosis
patients = []
for index, row in aki.iterrows():
    patients.append(row['SUBJECT_ID'])
```

Afbeelding 4: Een overzicht van de relevante code voor het selecteren van de urine gehalten van patiënten (P.23)

```
for index, row in out.iterrows():
    new = [row['SUBJECT_ID'], row['HADM_ID'], 43175, 0, -1, -1, row["VALUE"]]
    data.loc[len(data.index)+1] = new
```

Afbeelding 5: Een overzicht van de relevante code voor het selecteren van de urine gehalten van patiënten (P.24)

```
for i in markers:
    for index, row in data.iterrows():
        if row["ITEMID"] == i:
            data.loc[data["HADM_ID"] == row["HADM_ID"], i] = row["VALUENUM"]
```

Afbeelding 6: Een overzicht van de relevante code voor het berekenen van de leeftijd van patiënten (P.24)

```
# Register time of birth in data table
for index, row in pat.iterrows():
    data.loc[data['SUBJECT_ID'] == row['SUBJECT_ID'], 'DOB'] = row['DOB']

# Register time of admission in data table
for index, row in adm.iterrows():
    data.loc[data['SUBJECT_ID'] == row['SUBJECT_ID'], 'ADMITTIME'] = row['ADMITTIME']

# Register age in patients table
for index, row in data.iterrows():
    age = rdelta = relativedelta(datetime.strptime(row['ADMITTIME'], '%Y-%m-%d %H:%M:%S').date(), datetime.strptime(row['DOB'], '%Y-%m-%d %H:%M:%S').date())

    if age.years > 100:
        age.years = 90
    data.loc[data["SUBJECT_ID"] == row["SUBJECT_ID"], "AGE"] = age.years
```

Afbeelding 7: Een overzicht van de relevante code voor het opzetten van de doelvariabele (P.24)

```
data["AKI"] = 0
data.loc[data["SUBJECT_ID"].isin(patients), "AKI"] = 1
```

Afbeelding 8: Een overzicht van de relevante code voor het weergeven van de ROC curve (P.25)

```
# False positives and true positive rates
fpr, tpr, _ = metrics.roc_curve(y_test, y_pred)

# Calculate AUC
auc = metrics.roc_auc_score(y_test, y_pred)

# Plot ROC curve
plt.plot(fpr, tpr, label="AUC="+str(auc))
plt.title("*Name of used model*")
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.legend(loc=4)
plt.show()
```

Afbeelding 9: Een overzicht van de relevante code voor het weergeven van de prestatie van een model (P.25)

```
print(classification_report(y_test, y_pred))
```

Afbeelding 10: De prestaties van het KNN model bij n=1 (P.26)

n=1		precision	recall	f1-score	support
	0	0.99	0.98	0.99	2680
	1	0.96	0.97	0.97	1190
	accuracy			0.98	3870
	macro avg	0.97	0.98	0.98	3870
	weighted avg	0.98	0.98	0.98	3870

Afbeelding 11: De prestaties van het NB model (P.26)

		precision	recall	f1-score	support
	0	0.79	0.89	0.84	2680
	1	0.65	0.45	0.53	1190
	accuracy			0.76	3870
	macro avg	0.72	0.67	0.69	3870
	weighted avg	0.74	0.76	0.74	3870

Afbeelding 12: De prestaties van het Logistic Regression model (P.27)

	precision	recall	f1-score	support
0	0.82	0.81	0.82	2680
1	0.59	0.60	0.60	1190
accuracy			0.75	3870
macro avg	0.71	0.71	0.71	3870
weighted avg	0.75	0.75	0.75	3870

Afbeelding 13: De prestaties van het SVM model (P.27)

	precision	recall	f1-score	support
0	0.84	0.83	0.83	2680
1	0.62	0.64	0.63	1190
accuracy			0.77	3870
macro avg	0.73	0.73	0.73	3870
weighted avg	0.77	0.77	0.77	3870

Afbeelding 14: Een overzicht van de relevante code voor het berekenen van de AUC waarden voor  $n = [1,5]$  (P.28)

```
i = 0
while i < 5:
    i += 1
    knn_model = KNeighborsClassifier(n_neighbors=i)
    knn_model.fit(x_train, y_train)
    y_pred = knn_model.predict(x_test)
    print(f"{i}: {metrics.roc_auc_score(y_test, y_pred)}")
```

Afbeelding 15: De code die het machine learning model download (P.29)

```
joblib.dump(knn_model, 'aki_diagnoser.joblib')
```

Afbeelding 16: De code die het machine learning model laadt (P.29)

```
model = joblib.load('aki_diagnoser.joblib')
```

Afbeelding 17: Een weergave van de code die benodigd is om voorspellingen te doen met het model (P.29)

```
prediction = model.predict([[1.5,11,-1,75]])
print(prediction)
```

## Tabellen

Tabel 1: Een weergave van een verwarringsmatrix. (P.12)

	Positief voorspeld	Negatief voorspeld
Gelabeld als positief	80	20
Gelabeld als negatief	5	195

Tabel 2: een overzicht van alle variabelen en hun locaties binnen de dataset. (P.22)

Variabele	Locatie
Leeftijd	DOB (patients.csv) - Admittime (admissions.csv)
Diagnose	Diagnosis (admissions.csv) & ICD9_Code (diagnosis_icd.csv)
Serum creatinine	Itemid, Valuenum (labevents.csv)
Ureum	Itemid, Valuenum (labevents.csv)
Urine output	Itemid, Valuenum (outputevents.csv)

Alle benodigde bestanden: *outputevents.csv*, *labevents.csv*, *admissions.csv*, *diagnosis\_icd.csv*, *patients.csv*, *admissions.csv* (en de dictionaries: *d\_icd\_diagnoses.csv*, *d\_items.csv*, *d\_labitems.csv*)

Tabel 3: Een overzicht van de vijf getrainde modellen, gerangschikt op AUC van hoog naar laag (P.28)

Rang	Model	AUC
1	K Nearest Neighbors	0.98
2	Neural Network	0.83
3	Support Vector Machine	0.73
4	Logistic Regression	0.71
5	Naive Bayes	0.67


Tabel 4: Een overzicht van de AUC waardes voor  $n = [1,5]$  (P.28)

$n$	AUC
1	0.98
2	0.91
3	0.87
4	0.84
5	0.82

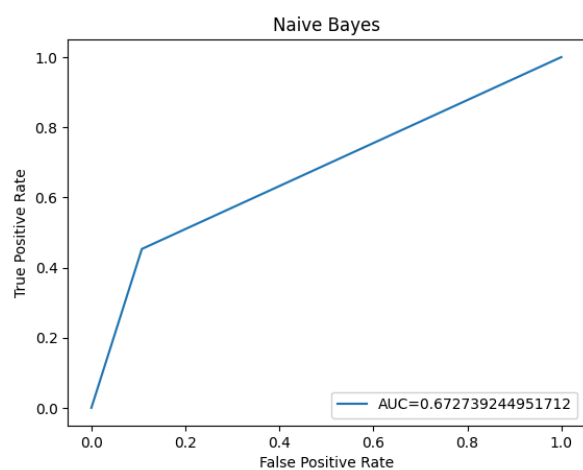


## Grafieken


Grafiek 1: De ROC curve van het KNN model (P.26)



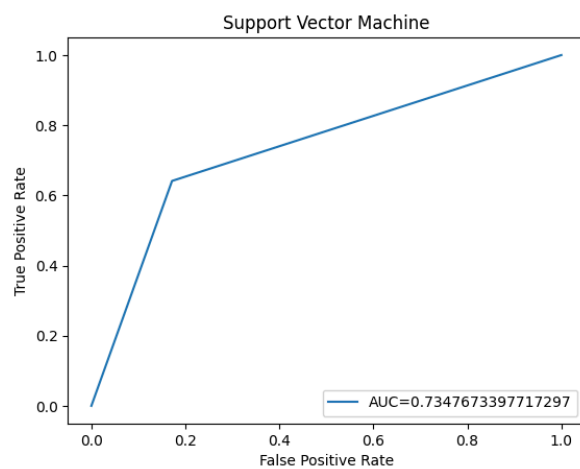
Grafiek 2: De ROC curve van het NB model (P.26)




Grafiek 3: De ROC curve van het Logistic Regression model (P.27)



Grafiek 4: De ROC curve van het SVM model (P.27)



Grafiek 5: De ROC curve van het NN model (P.27)



## Bijlage

<i>Bestandsnaam</i>	<i>Doel</i>
ADMISSIONS	overzicht inschrijvingen ziekenhuis
CALLOUT	Locatie patiënt (CCU, ICU)
CAREGIVERS	Verzorger patiënt
CHARTEVENTS	verzamelde data over patient
CPTEVENTS	Medische ingrepen/services
D_CPT	codes gerelateerd aan CPT
D_ICD_DIAGNOSES	medische diagnose met idc-9 code
D_ICD_PROCEDURES	medische procedures beschreven door ICD-9-codes
D_ICD_ITEMS	beschrijving stofjes (cholesterol etc)
D_ICD_LABITEMS	beschrijving stofjes uit laboratorium
DATETIMEEVENTS	medische events + wanneer
DIAGNOSES_ICD	diagnoses per patiënt + icd code
DRGCODES	Diagnosis-Related Group (DRG), per patiënt. IN welke groep zit patiënt
ICUSTAYS	intensive care afdeling
INPUTEVENTS_CV	medicatie of vochtinname
INPUTEVENTS_MV	uitgebreide info patiënt + medicatie vochtinname
LABEVENTS	labaratorium events +stof+ is iets mis?
MICROBIOLOGYEVENTS	bloedkweekmonsters, de micro-organismen die in de monsters worden aangetroffen en de resultaten van tests op gevoeligheid voor antibiotica.
NOTEEVENTS	(PRIVE) bevat info over notities CG
OUTPUTEVENTS	toediening van een bepaalde hoeveelheid van een stof aan een patiënt,
PATIENTS	patiënten + gender + dob/dod
PRESCRIPTIONS	patiënt, medicijn en details recept zelf, inclusief dosering

PROCEDUREEVENTS_CV	procedures op patiënten
PROCEDURES_ICD	procedures + icd code
SERVICES	services + waar patiënten eerder waren
TRANSFERS	verplaatsingen binnen het ziekenhuis, inclusief opnames, overdrachten tussen eenheden of afdelingen, en ontslagen

Tabel 4: Een overzicht van alle beschikbare bestanden en een korte beschrijving van de MIMIC-III dataset (Johnson et. al., 2016)

## Procesverslag

In september 2023 zijn we begonnen aan dit onderwerp. In eerste instantie leek het erg gecompliceerd om biologie en informatica te combineren, maar later bleek dit wel mee te vallen. Het eerste idee voor het profielwerkstuk was om machine learning te gebruiken om DNA te analyseren. Toen we erachter kwamen dat dit vrijwel onmogelijk was voor twee middelbare scholieren, hebben we met mevrouw Vries afgesproken om het eerste gesprek te voeren. Wij hebben via teams maar ook in kleine gesprekken voorafgaand aan dit gesprek duidelijk gemaakt wat we met haar wilden bespreken: een goed alternatief onderwerp. Uiteindelijk hebben we ook aan mevrouw Steiger gevraagd om ons te begeleiden bij het informatica gedeelte. Omdat zij ons in eerste instantie alleen bij de praktijk zou ondersteunen, hebben we de eerste gesprekken alleen met mevrouw Vries gevoerd. Na het eerste gesprek, dat plaatsvond op de eerste PWS middag, hebben we met een hint van mevrouw Vries het definitieve onderwerp gevonden: machine learning in de zorg.

Een groot deel van de communicatie tussen ons en onze begeleiders vond plaats via teams. Aan het einde van november 2023 hebben we met mevrouw Vries afgesproken om een toelichting te geven op onze ideeën voor het PWS. Dit was het go-no-go gesprek en we kregen van mevrouw Vries het groene licht om aan de slag te gaan. Bij dit gesprek hebben we haar onze taakverdeling uitgelegd, de manier waarop we het PWS wilden vormgeven toegelicht en hebben we haar ondersteuning gevraagd bij het aanvragen van de MIMIC-III dataset. Het plan van aanpak is dus tijdens het go-no-go gesprek besproken en goedgekeurd door mevrouw Vries.

## Interviews met zorgprofessionals voor nieuwe inzichten

### Gesprek met Johan Schuijtemaker

Denkt u dat het gebruik van machine learning in de zorg de medische besluitvorming kan ondersteunen?

- Ja, dat denk ik zeker. Ik denk dat, wat je nu ziet gebeuren, de eerste stappen zijn. Bijvoorbeeld in het interpreteren van gegevens zoals beeldvorming, dus de radiologie met scans en het beoordelen van scans. Dat artificial intelligence met grote databases de afwijkingen gaat opsporen.

Wat verwacht u dat de potentiële impact is van machine learning technologie op de patiëntenzorg/behandeling uitkomsten?

- Ik denk dat wat heel gunstig gaat zijn, dat je heel snel heel veel data kan analyseren, waar je zelf niet de tijd voor hebt. Dus dat je uit het dossier van een patiënt snel allerlei data haalt en een diagnose stelt, dus potentiële ziektes opspoort. Waar ik het risico in zie, is dat zoveel data ook weer gegenereerd wordt, dat dokters die allemaal ook weer moeten controleren. Gaan we vertrouwen op machine learning en wat er uit komt, of zullen wij zelf daar altijd nog naar moeten kijken? Wie is er verantwoordelijk?

Wat zijn volgens u de belangrijkste ethische kwesties rond het gebruik van machine learning in de gezondheidszorg?

- Nummer één is de verantwoordelijkheid, wie is er uiteindelijk verantwoordelijk van wat er uiteindelijk gezegd wordt? Bij de ethische kwesties zie ik het probleem van dat je niet goed weet hoe dat apparaat aan de data komt, dus via welk algoritme, want het zijn niet de medici en medische wetenschappers die dat erin hebben gestopt maar uiteindelijk zijn dat grote tech bedrijven. Die bedrijven maken keuzes, en dat kan ook ten goede wil zijn, maar die maken dus wel keuzes, die eigenlijk veel meer zouden moeten liggen bij medische professionals of bij de overheid. Welke data wordt er onderzocht en wat lekt er toch nog weg of wat blijft er, dat zijn toch nog wel problematische vlakken.

Heeft u ideeën/inzichten over privacy waarborging?

- Nou ik denk dat dat heel lastig wordt. Als je het over gezondheidszorg hebt, zal een patiënt heel snel overal ja op zeggen. 'Vind u het goed dat ik uw gegevens deel met de apotheek?' 'Ja, natuurlijk dokter.' 'Vindt u het goed dat ik het naar de huisarts stuur?' 'Ja, natuurlijk dokter.' En dan krijg je straks dus ook, 'Vind u het goed dat we een apparaat mee laten denken over uw ziekte?' 'Ja, natuurlijk dokter.' Maar ik

denk dat veel mensen dan niet beseffen, dat dat een apparaat van een groot bedrijf kan zijn die dat allemaal onderzoeken, en dus bepaalde complicaties niet snappen.

Wie zal volgens u de schuld op zich moeten dragen als er iets mis gaat bij het gebruiken van een machine learning algoritme in de zorg?

- Goede vraag! Wie de schuld krijgt.. het apparaat zelf. Die moet dan een entiteit krijgen. Hij wordt dan onderdeel van de behandelaren. Dus dan heb je bijvoorbeeld een dokter, een verpleegkundige, en dus 'A.I.', en dan ligt de schuld bij A.I. Het moet dan onderzocht worden als er iets fout gaat. Het algoritme erachter moet dan veranderd worden. A.I. leert ook zelf, dus maakt het zelf verkeerde keuzes, of misschien goede keuzes die wij juist niet zo snel zien. En wat nou als het apparaat denkt, voor het grotere belang moet ik deze patiënt zo behandelen, zodat ik andere patiënten in leven kan houden. Als je zo'n apparaat keuzes laat maken, zal het, als je kijkt naar de hoeveelheid geld en resources, in een pandemie andere keuzes maken dan wij zouden willen, op ethisch niveau.

Wat zijn volgens u de uitdagingen bij het implementeren van machine learning in ziekenhuizen?

- Ik denk dat het risico is dat er te groot begonnen wordt met te hoge verwachtingen. Je moet hele kleine stapjes maken. Het allerbelangrijkste is de verantwoordelijkheid, want ik kan nu al zeggen dat ik het echt niet ga gebruiken als ik niet goed weet en snap hoe antwoorden tot stand komen waar ik voor verantwoordelijk voor ben. Nu kun je het een beetje vergelijken met als ik literatuur opzoek. Nu kan je literatuur nog beoordelen, op basis waar het vandaan komt, maar bij AI is het lastiger. Is het nou plausibel? Past het een beetje in wat ik denk? Maar toch is het heel lastig, omdat je niet weet waar hij zijn kennis precies vandaan haalt.

Denkt u dat medisch personeel het zou kunnen accepteren? War voor factoren zouden van invloed kunnen zijn?

- Als je moet, dan moet je, want het gaat komen. Je moet klein beginnen en ze vanaf het begin meenemen. Laat ze meedenken over welke meerwaarde het heeft. Ook moeten de ethische kwesties geadresseerd worden.

Heeft u nog enige opmerkingen/een mening/zorgen/ideeën voor een vervolgonderzoek over het onderwerp?

- Waar ik me zorgen over maak, is dat het alleen maar meer werk gaat opleveren. Zolang de verantwoordelijkheid niet elders ligt, moet je alsnog naar de dokter. Het aantal ongeruste mensen zal toenemen. Op het gebied van machine learning technieken, denk ik dat je met machine learning wel echt in de preventie

problematiek krijgt, want dan kom je wel echt een gevaarlijk stukje tegen, de privacy. Maar je kan wel heel snel, heel gericht bevolkingsonderzoek doen, maar dan heb je wel al die gegevens nodig van al die mensen dus dan is er wel risico. Dus de gegevens en hoe dat gewaarborgd wordt en gebruikt wordt. Op het gebied van baanverlies maak ik me dan geen zorgen, want ik was eens op een congres en daar werd gezegd: 'AI won't replace doctors, only those who don't use it.' het moet dus echt als een tool gebruikt worden in de toekomst.

### Gesprek met Marein van der Torn

Het audiobestand met het volledige gesprek met Marein van der Torn kunt u via de onderstaande link beluisteren:

 [Gesprek Marein van der Thorn.m4a](#)

# Logboek

Wie	Wat	Wanneer	Tijd	Opmerkingen
Mina	Brainstormen PWS ideeën, overleg met Santos	Augustus 2023	1 uur	
Santos	Bekijken van TedX talks over bioinformatica en scriptiebank van uva doorzoeken voor soortgelijke onderzoeken	23-09-23	5 uur	Geannoteerde versie van de gelezen scriptie is in de drive te vinden. Bevat veel informatie die wij ook kunnen gebruiken en een duidelijke beschrijving van het proces. (Machine Learning For...)
Santos	Scripties lezen + zoeken naar manieren om DNA te analyseren + genome datasets zoeken	25-09-23	2 uur	
Mina	Onderzoeken en oriënteren naar PWS ideeën, plan van aanpak, etc.	Verschillende data	3 uur	
Mina	Scriptie lezen	Verschillende data	4 uur	
Mina+ Santos	Dieper ingaan op de PWS ideeën	23-08-23	1 uur	
Mina+ Santos	Onderzoeksvraag bedenken + specifieker worden over het onderwerp	27-09-23	2 uur	
Santos	Zoeken naar nieuw onderwerp + goeie databases	28-09-23	1.5 uur	Na overleg met Mina hebben we geconcludeerd dat ons onderwerp geen echte toepassing had op de echte wereld, en dus ben ik gaan zoeken naar alternatieven
Mina & Santos	Sparren met Vries	03-10-23	1 uur	We hebben eindelijk een ECHT idee.
Santos	Video kijken over Machine Learning	14-10-23	4 uur	
Santos	Databeschrijving MIMIC-III	15-10-23	30 min	



Santos	Databeschrijving MIMIC-III	16-10-23	30 min	
Mina	Ziekten onderzoeken, zoeken naar geschikte voor ons pws		2 uur	
Mina	toch gekozen voor acuut nierfalen → daar is een grote database van			
Santos	Nieuwe invalshoek bij pws bedenken	23-10-23	30 min	
Santos	Nieuwe onderzoeksvraag en deelvragen bedenken	25-10-23	1 uur	
Santos	Onderzoeksvragen bijbedenken	14-11-23	15 min	Mina wilde meer biologie gerichte onderzoeksvragen
Santos	Stappenplan voor aanvraag MIMIC-III uitschrijven	22-11-23	1.5 uur	
Santos	Theoretisch kader en inleiding schrijven	22-11-23	2 uur	
Santos	Theoretisch kader hoofdstuk 1	05-12-23	3 uur	
Santos	Theoretisch kader hoofdstuk 2	06-12-23	3 uur	
Mina	Werken aan theoretisch kader	06-12-23	3 uur	
Santos	CITI Research or Specimens only course doorlopen	15-12-23	4 uur	
Santos	Theoretisch kader hoofdstuk 2.2 en 2.3	17-12-23	3 uur	
Santos	Met mevrouw Vries aanvragen voor de datasets regelen	21-12-23	1 uur	
Mina	Filmpjes kijken en artikelen lezen over de meer biologische kant van ons pws	30-12-23	3 uur	
Santos	Theoretisch kader hoofdstuk 4.1-4.3 + deeltitels bedacht	30-12-23	5 uur	
Santos	Theoretisch kader hoofdstuk 2.3 en 2,4	2-1-24	3 uur	
Mina	Werken aan verslag	3-1-24	6 uur	
Santos	Theoretisch kader hoofdstuk 2.4-2.5 + bronnen uitzoeken	4-1-24	1.5 uur	

Santos	Theoretisch kader hoofdstuk 2.5	5-1-24	1.5 uur	
Mina	Werken aan verslag	6-1-24	5 uur	
Santos	Theoretisch kader hoofdstuk 4.4	6-1-24	1.5 uur	
Mina	Werken aan verslag	7-1-24	4 uur	
Mina	Proofreaden op grammatica + spelling, opmaak, netter maken etc.	7-1-24	2 uur	
Santos	Begin aan Deel 1 (data opschonen)	9-1-24	2 uur	
Mina	Variabelen onderzoeken en in verslag zetten	10-1-24	2 uur	
Mina	N.a.v. feedback dokters & ziekenhuizen zoeken en mailen, enquête mailen	19-1-24	2 uur	Veel afgewezen door drukke chirurgen..
Mina	Arts gevonden, via de arts ook contact gekregen met de CMIO Dijklander ziekenhuis			29 januari afspraak met Johan, afspraak met Marein nog niet bekend
Mina	Begin aan presentatie pws	28-1-24	1 uur	
Santos	Deel 1: casus en inleiding, ML-model stap 1: data opschonen	27-1-24	6 uur	
Santos	Deel 1: Datamanipulatie en KNN	28-1-24	7 uur	Heel veel debugging! Er moet een afweging gemaakt worden tussen het gebruiken van de complete dataset en het besparen op tijd. Het analyseren van alle benodigde data zal namelijk naar schatting zo'n 12 uur per keer duren, wat debuggen onmogelijk maakt. Daarnaast is te zien aan de grafieken dat de modellen niet leren en op een constant niveau functioneren. Misschien is het beter om de gebruikte variabelen te herevalueren in een nieuw model.

Mina	Gesprek met Johan Schuijtemaker	29-01-24	2 uur	
Santos	Begonnen aan nieuw model (2) (fase: datamanipulatie)	30-01-24	7 uur	Het oude model had geen ruimte voor verbetering en dus is de afweging gemaakt om vanaf de start met een nieuwe aanpak te beginnen
Mina	Gesprek met Marein van der Torn	31-01-24	3 uur	
Mina	Video over machine learning kijken	31-01-24	4 uur	
Santos	Werken aan verslag: hoofdstukken 1.1, 1.2 van deel 1 geschreven	01-02-24	2 uur	
Santos	Werken aan model 2 (fase: datamanipulatie)	04-02-24	3 uur	
Mina	Aantekeningen gesprek maken en aanvullen met opname	06-02-24	3 uur	
Mina	Interviews verwerken in bijlage (audio overtypen)	07-02-24	6 uur	Begonnen met typen interview Marein van der Torn, maar was extreem lang, dus we hebben het gelaten bij een audiobestand. De transcriptie van Johan Schuijtemaker is wel gelukt.
Santos	Werken aan model 2 (fase: datamanipulatie)	08-02-24	2 uur	Het nieuwe model blijkt iets te complex te zijn, wat erg veel bugs oplevert. Misschien is het beter om het oude model (de 'nulversie') weer te gebruiken.
Mina	Voorwoord en inleiding schrijven	11-02-24	1 uur	
Mina	Feedback verwerken	12-02-24	5 uur	
Santos	Terug naar nulversie (nieuwe technieken toegepast)	13-02-24	5 uur	De afweging om terug te gaan naar het oude model is een goede keuze geweest! Door de variabele leeftijd aan de dataset toe te voegen

				is de AUC van het KNN model toegenomen naar 0.98, en in sommige gevallen zelfs naar 1.00. Dit betekent dat de prestatie van het model zowat perfect is.
Santos	Model finetunen en hoofdstuk 1.3 van deel 1 schrijven	14-02-24	3 uur	
Mina	Aan presentatie werken	14-02-24	5 uur	Inhoud van PWS toevoegen
Mina	Missende onderdelen verslag toevoegen	15-02-24	3 uur	
Santos	Model finetunen	15-02-24	2 uur	
Mina	Interviews verwerken in verslag	15-02-24	4 uur	
Mina	Aan presentatie werken	16-02-24	4 uur	
Santos	Code van model opschonen, hoofdstuk 1.4 schrijven, met mevrouw Steiger spreken over pws-technische zaken, puntjes op de i zetten van het verslag, literatuurlijst aanvullen met afbeeldingen, tabellen, etc.	16-02-24	4 uur	Alle code en benodigde bestanden van het model staan nu ook op <a href="#">github</a> !
Mina	Spellingscheck, bronnen nakijken, opschonen, puntjes op de i zetten	16-02-24	1 uur	